Le code source du droit : traquer par *red-teaming* les contradictions et les failles d'une loi réécrite par l'IA

Alexandre Masmejean* Indépendant

Nathalie Gouailhardou Indépendante

Kevin Primicerio Indépendant

31 octobre 2026

Résumé

Traduire un programme politique en droit applicable exige de modifier un corpus vaste et interconnecté : lois, décrets, annexes fiscales et versions futures, qui se contredisent souvent. Nous étudions si une chaîne d'agents d'IA, configurable par un programme politique, peut faire cette traduction de façon cohérente, vérifiable et bien moins coûteuse que la rédaction manuelle. Cas d'étude : cinq grands codes français complets (travail, CGI et ses quatre annexes, sécurité sociale, urbanisme, construction et habitation), soit 30 317 articles de la base LEGI au 18 octobre 2026, réécrits selon des réformes inspirées du programme 2027 de David Lisnard, dans un projet indépendant. Le travail a suivi trois passes et une relecture publique ouverte : réécriture de chaque article (14 115 réécrits, 16 199 maintenus avec justification), relecture de cohérence complète, puis une red team distincte qui a appliqué 1 285 corrections et mesuré la fiabilité par des audits aléatoires à l'aveugle. Sur deux nouveaux échantillons de 1 264 articles jamais tirés auparavant, audités à l'aveugle sur les deux textes avec le même protocole, le droit réécrit compte **54 % de défauts grossiers en moins** que le droit en vigueur (IC à 95 % : 40 à 64 %) : 3,5 % ± 1,0 contre 7,5 % ± 1,5 (test apparié, $p \approx 2 \times 10^{-10}$). Le coût est 2 500 à 10 000 fois inférieur aux estimations du même travail par des juristes. Le programme est une entrée distincte : la détection des défauts ne dépend pas de lui, et nous invitons à faire passer d'autres programmes par la même chaîne. Ces résultats, produits et mesurés par l'IA seule, sont publiés pour que juristes et citoyens les vérifient.

Note : cette version française est une traduction de l'article original, rédigé en anglais. En cas de divergence, la version anglaise fait foi.

Résultat clé. Mesuré de la même façon sur les mêmes articles tirés au hasard, le droit réécrit par l'IA compte **54 % de défauts grossiers en moins** que le droit français en vigueur : 3,5 % des articles contre 7,5 % (1 264 articles, IC à 95 % de la baisse : 40 à 64 %). **Le taux mesure surtout la cohérence (renvois, versions, contradictions, transitions) ; il ne juge ni la conformité au droit de l'Union ou à la Constitution (F9, « à confirmer »), ni l'opportunité des réformes.** Pour un coût **2 500 à 10 000 fois moindre** aux points médians (les fourchettes du tableau 9 vont de 1 300 à 28 000, hors temps humain de direction, et les heures de juriste sont des hypothèses) que le même travail par des juristes (ordres de grandeur, §7.7). Aucun article n'a été relu par un juriste : ces textes sont une base de travail vérifiable, pas une proposition de loi prête à déposer.

*Auteur correspondant : alex@masmej.com. Alex Masmej sur X : https://x.com/AlexMasmej.

1 Introduction

La lisibilité, une exigence juridique. L'accessibilité et l'intelligibilité de la loi sont, en France, un objectif de valeur constitutionnelle [2]. Le Conseil d'État critique depuis des décennies l'inflation et l'instabilité des textes [3].

Le problème n'est pas seulement le volume. Une même règle se répartit entre plusieurs textes :

— une loi (partie législative) ;

— ses décrets d'application (partie réglementaire) ;

— pour la fiscalité, les quatre annexes du CGI ;

— des versions consolidées futures, déjà publiées mais pas encore en vigueur.

Quand l'un de ces textes change et pas les autres, des contradictions apparaissent. Certaines viennent des sources officielles elles-mêmes ; d'autres naissent de la réforme.

Origine de ce travail. Le 19 octobre 2026, le premier auteur a publié un court fil en français [4]. Il répondait à un défi public et annonçait que des agents d'IA avaient produit, en une nuit, des versions réécrites de plusieurs codes français, publiées sur cinq sites thématiques. Le fil invitait juristes, économistes, salariés et entrepreneurs à critiquer les propositions article par article.

L'accueil a été bien plus large que prévu : environ 120 000 vues, 1 190 mentions « j'aime », 201 republications et 293 signets au dernier relevé. Les critiques qui ont suivi ont été plus utiles encore. Elles ont montré qu'un premier jet rapide ne suffisait pas, et qu'une démonstration crédible demandait trois choses :

(i) les codes complets, pas une sélection ;

(ii) une recherche systématique des contradictions ;

(iii) une mesure honnête de ce qui reste faux.

Cet article documente cette seconde phase, plus lente.

Pourquoi maintenant : l'élection présidentielle de 2027. La France élira son prochain président de la République en 2027, au terme du mandat de cinq ans en cours [1]. Les partis y présenteront des réformes de la fiscalité, du travail, des retraites, du logement ou de la réglementation des entreprises. Une promesse de réforme n'est pas encore du droit : pour s'appliquer, elle doit être traduite en modifications précises de lois et de règlements, à travers un corpus vaste et interconnecté. Ce travail de traduction est aujourd'hui long, coûteux et difficile à vérifier de l'extérieur.

L'échéance de 2027 offre donc un cas d'usage concret et immédiat à l'ingénierie législative assistée par IA, quel que soit le vainqueur et quelle que soit l'ampleur des réformes qui suivront. Nous ne prétendons pas qu'une réforme de cette ampleur aura lieu ; nous examinons si des agents d'IA peuvent rendre cette traduction nettement moins chère, plus rapide, plus systématique et plus facile à auditer.

Question de recherche. *Une chaîne multi-agents généraliste, configurable par un programme politique, peut-elle traduire des objectifs de réforme ambitieux en modifications cohérentes et vérifiables d'un corpus juridique national, à un coût bien inférieur à celui d'une rédaction manuelle ?*

Nous la décomposons en trois objectifs :

— **La lisibilité.** Produire, pour chaque article du périmètre, un texte proposé complet, présenté en regard de la source officielle et accompagné d'une justification écrite.

— **La cohérence.** Montrer comment des agents d'IA peuvent trouver et résoudre les contradictions d'un vaste corpus interconnecté, et jusqu'où. Réformer un code est simple à énoncer et difficile à faire de façon cohérente : supprimer une obligation dans une loi n'a pas de sens si un décret, une annexe fiscale ou une version consolidée future continue de l'imposer.

— **La configurabilité.** Séparer le programme politique, traité comme une entrée, de l'infrastructure de réécriture et de vérification, et dire ce qui, dans cette infrastructure, en dépend encore.

Contributions.

— Une architecture en quatre couches, qui sépare la *spécification des politiques* (quels objectifs mettre en œuvre) de la *transformation législative* (comment les traduire en modifications du droit), de la *vérification de cohérence* (contradictions, renvois morts, dispositions incompatibles, erreurs de mise en œuvre) et de l'*évaluation indépendante* (§4.1). Nous indiquons précisément quelles parties de l'infrastructure actuelle dépendent encore du programme choisi.

— Une réécriture complète de cinq grands codes et des quatre annexes du CGI (30 317 entrées), en trois passes et une relecture publique ouverte ; chaque version est conservée et publiée. Sources officielles et propositions sont tenues séparées, avec un lecteur comparatif et des téléchargements (§3–§4).

— Un protocole de « red teaming » pour la législation produite par IA :

  — instantanés figés, dont chaque fichier est identifié par une empreinte numérique (hachage SHA-256) ;

  — un registre d'objections, avec priorités et natures ;

  — un réexamen sur les différences ;

  — une correction soumise à un critère d'alignement explicite ;

  — un outil d'écriture contrôlée, qui ne peut rien écraser sans vérification (§5).

— Une méthode de mesure : six audits aléatoires stratifiés, menés à l'aveugle, avec une taxonomie de dix familles de défauts (F1 à F10). Le taux s'accompagne d'un intervalle de confiance, pas d'une anecdote (§6).

— Une référence appariée : le même audit mené sur le droit officiel, sur les mêmes articles. Le droit réécrit compte 34 % de défauts grossiers en moins que le droit qu'il remplace sur 1 879 articles à la date des audits (4,6 % contre 7,0 %), et **54 % de moins** sur deux nouveaux échantillons de 1 264 articles tirés en fin de travail (3,5 % contre 7,5 %) (§7.3, §7.4).

— Une comparaison de coût : environ 1 400 dollars déboursés, 3 500 à 5 100 dollars au prix de l'API, contre des ordres de grandeur de 6 à 36 millions d'euros pour le même travail par des juristes, soit 2 500 à 10 000 fois plus aux points médians (les fourchettes du tableau 9 vont de 1 300 à 28 000, hors temps humain de direction, et les heures de juriste sont des hypothèses ; §7.7).

— Des constats empiriques sur ce que les agents d'IA font bien et mal en matière de cohérence juridique (§7–§8) :

  — les balayages mécaniques atteignent un plateau ;

  — les tours de correction peuvent créer de nouveaux défauts ;

  — une large part de l'erreur résiduelle vient de textes hors du corpus.

Le projet en un coup d'œil. Le tableau 1 résume l'ensemble : trois passes sur les cinq codes et les quatre annexes fiscales, une relecture publique ouverte, et les mesures présentées ici.

Étape	Dates (oct. 2026)	Agents	Ce qu'elle a fait
Passe 1 : rédaction	18–23	Codex d'OpenAI (`gpt-6-astra`)	A lu chaque article en entier et rédigé une proposition complète : 14 115 réécrits, 16 199 maintenus avec une justification écrite.
Passe 2 : cohérence	23–29	Codex d'OpenAI (`gpt-6.1-sol`)	A relu les 30 314 propositions au regard de leurs sources et contreparties, contradictions d'abord ; 2 894 sessions d'agents.
Passe 3 : red team	26–31	Claude Code (Opus 5.5, Fable 5.1)	Environ 570 exécutions d'agents : 303 objections soulevées, 243 retenues ; 1 285 corrections sur 1 211 articles ; lecture complète des 2 740 articles fiscaux réécrits.
Relecture publique	dès le 27	Contributeur externe, lecteurs	13 signalements (« issues ») et 2 demandes de fusion sur GitHub, dont neuf des onze premières visaient un vrai défaut ; triées au fil de l'eau ; toutes ont reçu une réponse à la date de cette version.
Mesure	29–31	Auditeurs IA à l'aveugle	Huit audits aléatoires (3 143 articles lus à l'aveugle) et trois comparaisons appariées avec le droit officiel.

TABLE 1 – Le projet en un coup d'œil.

Des résultats produits par l'IA seule. Cet article rapporte délibérément ce que des agents d'IA ont accompli seuls. Rédaction, revue, correction et mesure ont toutes été faites par des agents d'IA, sous direction et arbitrage humains, mais sans juristes. Nous publions les résultats pour que juristes et citoyens les vérifient et les consolident (voir l'appel à contributions à la fin).

Un cas d'étude : le programme de David Lisnard. La première mise en œuvre utilise des réformes inspirées du programme 2027 de David Lisnard [5]. Ce choix fournit un jeu d'hypothèses concret et ambitieux pour éprouver une chaîne générale : moins d'impôts et moins de contraintes, conservation des exonérations, des dérogations favorables, des droits acquis et des transitions, et jamais de formalité de remplacement. C'est l'origine historique du projet, et nous la maintenons explicitement.

Ce projet est une initiative indépendante. Il n'est ni commandé, ni relu, ni approuvé par David Lisnard ni par son mouvement, Nouvelle Énergie, et les sites publiés le disent. Cet article ne soutient pas, scientifiquement, que ces orientations soient préférables à d'autres.

Nous distinguons quatre questions, qui relèvent de couches différentes :

— **Spécification des politiques :** quels objectifs politiques mettre en œuvre ? C'est l'entrée, ici le programme retenu ; la question n'est pas scientifique.

— **Transformation législative :** comment des agents d'IA traduisent-ils ces objectifs en modifications du droit existant ?

— **Vérification de cohérence :** comment détectent-ils les contradictions, renvois morts, dispositions incompatibles et erreurs de mise en œuvre ?

— **Évaluation indépendante :** comment évaluer le corpus obtenu sans privilégier une philosophie politique ?

Prendre un programme complet et ambitieux comme cap montre qu'une réforme de grande ampleur peut être rédigée de bout en bout avec l'IA, tout en restant moins défectueuse que le droit en vigueur (§7.4). Seule la première couche devrait changer avec un autre programme, qu'il soit libéral, centriste, socialiste, conservateur ou autre. La red team avait pour consigne de corriger les contradictions et les failles, *jamais* de modifier les choix politiques. La vérification et l'évaluation ne dépendent pas du programme ; la transformation en dépend par ses consignes, qu'il suffit de remplacer (§4.1).

2 Travaux connexes

Les grands modèles de langage sont de plus en plus évalués sur le raisonnement juridique, par exemple avec LegalBench [7]. Les travaux qui rendent la législation lisible par machine prennent deux formes :

— des langages de programmation pour les lois, comme Catala, appliqué au droit fiscal français [8] ;

— les initiatives « rules as code » [9].

Ces deux approches formalisent fidèlement le droit existant. Notre objectif est différent : nous *réécrivons* le droit selon un programme de réforme, puis nous vérifions la cohérence du résultat.

Le « red teaming », recherche contradictoire de défaillances par une partie indépendante, est une pratique courante pour les systèmes d'IA [10]. Il est ici retourné contre une législation produite par IA.

Nous ne connaissons pas de travail antérieur qui réécrive de bout en bout des codes nationaux complets et publie un taux de défauts mesuré. Nous situons ce travail dans une *ingénierie législative* : traiter un programme comme une spécification, le corpus juridique comme l'objet à transformer, et la cohérence du résultat comme une propriété à mesurer.

3 Corpus et périmètre

Le corpus est figé au **18 octobre 2026**. Il est construit à partir de la base officielle LEGI de la Direction de l'information légale et administrative (DILA) [6] : le stock du 13 juillet 2025, plus 466 mises à jour quotidiennes.

L'identité de travail d'un article est le couple (identifiant du code, identifiant de version `LEGIARTI`), accompagné d'une empreinte de sa source et de ses dates de validité. On ne se fie jamais au seul numéro, car les numéros sont recyclés. La base contient 135 904 versions historiques ; le périmètre couvre les 30 317 entrées en vigueur ou programmées (tableau 2).

Sont hors périmètre les textes que le corpus cite sans les contenir. Par exemple : le code monétaire et financier, le code de commerce, les lois non codifiées, les arrêtés, et le code des impositions sur les biens et services (CIBS), dans lequel une grande partie de la TVA est recodifiée au 1er janvier 2027. Cette frontière se révèle importante (§8).

4 Chaîne de rédaction (première et seconde passes)

4.1 Paramétrage du programme

La figure 1 résume l'ensemble de la chaîne. Toutes les décisions de fond sont stockées comme des fichiers de paramétrage explicites, dont chaque version est conservée, séparés du

Recueil	Entrées	Réécrits	Maintenus	Réserves
Code du travail	11 593	4 296	7 297	0
Code général des impôts (CGI)	2 375	1 387	988	0
Code de la sécurité sociale	7 427	3 178	4 247	2
Code de l'urbanisme	2 459	1 530	929	0
Code de la construction et de l'habitation	4 126	2 205	1 921	0
CGI, annexe I	71	42	29	0
CGI, annexe II	674	388	286	0
CGI, annexe III	1 115	799	316	0
CGI, annexe IV	477	290	186	1
Total	30 317	14 115	16 199	3

TABLE 2 – Périmètre à la fin de la seconde passe. Les articles « maintenus » sont conservés sans changement, avec une justification propre. Les trois « réserves » sont des lacunes documentaires (une figure manquante, des formulaires originaux manquants et un conflit dans la consolidation officielle) qui n'ont pas été comblées par supposition. Au commit 55621278, `progress.json` compte 14 273 articles rédigés et 16 041 maintenus après les requalifications de la troisième passe ; s'y ajoutent les 257 propositions sur des versions futures.

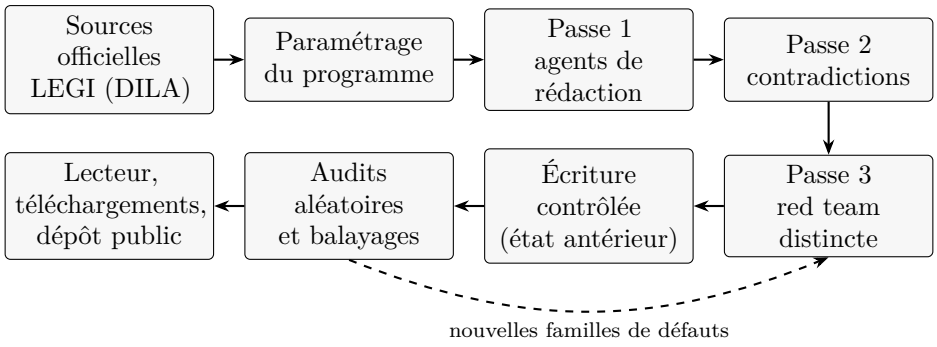


FIGURE 1 – Vue d'ensemble de la chaîne. Toute écriture passe par le même outil d'écriture contrôlée ; les audits renvoient de nouvelles familles de défauts à la red team.

texte juridique : coordinations par domaine, résumés des sites et méthode de chiffrage net des mesures fiscales. Exemples :

— un contrat de travail unique à durée indéterminée, avec un préavis de quinze jours de chaque côté ;

— un impôt sur les sociétés déclenché par la distribution ;

— la suppression des droits de succession, les donations restant taxées ;

— la suppression des impôts de production ;

— des délais d'instruction des permis raccourcis.

Le reste de la chaîne les traite comme des entrées.

Des invariants éditoriaux s'appliquent partout :

— les sources officielles ne sont jamais écrasées ;

— aucun taux, aucune date, aucune équivalence ni aucun fac-similé n'est inventé ;

— on ne supprime jamais une faveur pour rendre deux textes artificiellement cohérents ;

— une obligation supprimée dans une loi ne doit pas survivre dans un décret, un formulaire ou un renvoi.

Remplacer le programme. En principe, un autre programme remplacerait le paramétrage du programme sans toucher au reste. Le tableau 3 dit ce qui, dans la chaîne actuelle, dépend du programme et ce qui n'en dépend pas.

Élément	Dépend du programme	Ce qu'il faudrait changer
Fichiers de paramétrage (coordinations, résumés, chiffrage)	Oui	Les réécrire pour le nouveau programme. Ils ont été rédigés sous la direction de l'auteur, pas extraits automatiquement d'un programme.
Consigne de rédaction des agents	En partie	Remplacer l'instruction d'orientation (aujourd'hui : « couper davantage les taxes et les contraintes ») ; le reste (lire en entier, rendre l'article complet, ne rien inventer) est général.
Critère d'alignement de la red team	Oui	Le reformuler à partir du nouveau programme. Le principe (corriger contradictions et failles, renvoyer les arbitrages) reste.
Garde-fous, écriture contrôlée, validation	Non	Rien.
Audits, familles F1 à F7 et F9	Non	Rien. La famille F8 (« contraire aux orientations ») se recalcule avec le nouveau programme.
Référence sur le droit officiel	Non	Rien : elle ne lit aucun programme.

TABLE 3 – Ce qui dépend du programme dans la chaîne actuelle.

L'audit apparié du droit officiel (§7.3) montre que l'évaluation fonctionne sans aucun programme. En revanche, aucun autre programme n'a encore été mis en œuvre : la portabilité de la transformation elle-même n'est pas mesurée.

4.2 Agents par article

Chaque article, ou lot d'articles liés, est traité par un agent de programmation non interactif. L'agent reçoit :

— le XML source complet, avec ses notes (NOTA), ses tableaux et ses versions ;

— les politiques applicables ;

— les cibles de renvoi explicites.

Il doit rendre l'article proposé *complet*, jamais un résumé, avec un motif et des notes de revue. Il lui attribue l'un de deux statuts, `rewrite_draft` ou `retained_unchanged`. Les abrogations et réductions partielles sont typées (`full_repeal`, `normative_reduction`). Chaque disposition retirée est listée, pour qu'une réduction soit vérifiable.

La première passe a utilisé un modèle d'OpenAI (`gpt-6-astra`, effort moyen) via l'agent en ligne de commande Codex. La seconde passe a utilisé `gpt-6.1-sol` en effort élevé.

4.3 Seconde passe : les contradictions d'abord

À partir du 23 octobre, la priorité est passée des coupes supplémentaires aux *contradictions et incohérences* : dans un article, entre articles et entre les neuf recueils. Les 30 314 propositions antérieures ont toutes été relues au regard de leurs sources et contreparties complètes. Chaque agent a classé chaque tension trouvée parmi :

— une contradiction effective ;

— une coordination nécessaire ;

— une transition compatible ;

— une différence de champ ;

— un point invérifiable.

4.4 Garde-fous

Rien n'est accepté sur la seule parole d'un modèle. Une réponse n'est acceptée qu'après les contrôles suivants :

— la source, les NOTA et les dates de validité ;

— la validation du contenu, y compris le balisage autorisé et les tableaux complets ;

— un contrôle de l'état antérieur sur cinq champs canoniques (empreinte de source, statut, proposition, motif, notes), dans la base comme dans le fichier de lot propriétaire de l'article ;

— la propriété, le registre et l'archive ;

— une validation indépendante de tout le corpus.

Les preuves d'exécution natives (modèle, effort, session) sont aussi contrôlées.

Ces garde-fous ne sont pas décoratifs. Ils ont arrêté de vraies divergences : trois tâches de seconde passe ont été refusées parce que l'article avait changé entre-temps. Ils ont aussi rendu possible la troisième passe, puisque chaque correction a pu passer par le même écrivain.

La seconde passe s'est achevée le 29 octobre, avec l'acceptation des 30 314 identités. Un audit structurel a posteriori a ensuite relevé 94 059 points à examiner, dont 1 412 prioritaires, sur 792 articles. Ce sont des pistes, pas des contradictions établies.

5 Red team distincte (troisième passe)

La troisième passe a utilisé un autre système : Claude Code d'Anthropic (Claude Opus 5.5 ; le dernier cycle, l'audit 8 et ses corrections, a tourné sur Claude Fable 5.1). Un agent coordinateur a lancé environ 570 exécutions de sous-agents en six jours. Il a travaillé comme un relecteur *distinct des agents rédacteurs*, sous des règles strictes :

— lecture seule de la production, sur des instantanés figés dont chaque fichier est identifié par une empreinte numérique (hachage SHA-256) ;

— citations exactes, avec identifiant de version, pour toute affirmation ;

— aucune source, date ou « preuve de résolution » inventée ;

— aucun contournement de contrôle d'accès ;

— la mention explicite qu'une revue par IA ne vaut pas validation par un juriste.

5.1 Registre des objections

La première vague a couvert 31 dossiers thématiques (par exemple versions futures, décrets contre lois, annexes fiscales, transitions de la réforme des accidents du travail de 2026). Cinq domaines prioritaires ont suivi : l'impôt sur les sociétés à la distribution, les successions, les quotas de logements sociaux SRU, la CVAE et la taxe sur les salaires.

Chaque objection indique :

— une priorité : P0 (effet grave et certain), P1 (effet probable) ou P2 (effet limité) ;

— une nature : coordination manquante, incohérence introduite par le projet, risque juridique, conflit de source, anomalie d'inventaire, réserve documentaire ou simple alerte ;

— les passages exacts, le raisonnement et une *correction minimale* ;

— ce qu'il faut préserver : droits, faveurs et transitions.

Les 1 943 alertes structurelles jugées prioritaires par l'audit statique ont été qualifiées une à une. Les doublons ont été fusionnés avec un motif écrit (46 fusions).

5.2 Réexamen sur les différences

La seconde passe tournait encore quand la red team a commencé. Le registre a donc été réexaminé deux fois, sur un instantané intermédiaire puis sur l'instantané final, à partir d'un diff fichier par fichier. Sur le texte final, 136 objections dont l'article avait changé ont été relues :

— 58 étaient résolues par la seconde passe (dont 17 P1) ;

— 30 ont été reformulées ;

— 48 ont été maintenues.

Le registre final compte **243 objections** : 3 P0, 83 P1 et 157 P2, dont 188 confirmées et 55 à confirmer.

5.3 De la revue à la correction

Après la revue, le premier auteur a fait de la red team l'unique écrivain, avec une consigne permanente : les corrections peuvent lever des contradictions et fermer des failles, jamais changer des choix politiques. Une correction n'est appliquée que si elle fait l'une de ces trois choses :

(a) rendre effective une réforme décidée, par exemple en la reportant sur une version future publiée qui rétablirait sinon l'ancienne règle ;

(b) lever une contradiction ;

(c) fermer une faille qui contredit l'objet déclaré du projet.

Une correction est refusée si elle fait l'une des choses suivantes :

— créer ou augmenter un impôt ;

— ajouter une formalité ou une condition ;

— supprimer une exonération ou un droit acquis ;

— revenir sur un choix explicite de l'auteur ;

— trancher une question politique ouverte.

Les agents rédacteurs n'écrivent leurs corrections que dans un espace de travail, sous forme de textes d'articles complets avec des métadonnées typées. Un vérificateur reconstruit chaque ligne exactement comme le ferait l'applicateur de production, et lance le validateur du projet dans un répertoire temporaire.

Le coordinateur applique ensuite les corrections avec l'outil d'écriture contrôlée. Cet outil vérifie l'état antérieur, archive l'ancien texte, revalide tout le corpus et revient en arrière en cas d'échec. Une table de propriété attribue chaque article à un seul groupe. Les besoins entre groupes passent par des demandes, si bien que deux agents n'écrivent jamais le même article.

5.4 Contributions externes

Pendant la revue, un contributeur externe (le troisième auteur) a ouvert 13 signalements (« issues » GitHub) et deux demandes de fusion sur le dépôt public. Produites avec ses propres agents d'IA, elles portaient sur des renvois du code du travail, des décrets qui survivent à des lois abrogées, des sanctions et les commissions du CSE. Chaque issue a été triée par rapport au registre, sur le texte courant. Trois d'entre elles demandaient un changement d'orientation politique ; elles ont été expliquées et closes comme non retenues.

6 Mesurer la fiabilité

Un registre dit ce qui a été trouvé, pas ce qui reste. Nous avons donc mesuré directement le taux de défauts résiduel.

Échantillonnage. Chaque audit tire environ 314 articles au hasard. Le tirage est stratifié : le corpus est découpé en groupes, ou strates, selon le recueil et le niveau (législatif ou réglementaire), et chaque strate reçoit un nombre d'articles proportionnel à sa taille, avec au moins six articles. Chaque audit exclut tous les articles déjà lus. Le tirage est reproductible : la valeur de départ du générateur aléatoire (sa « graine ») est publiée, ce qui permet à quiconque de refaire exactement le même tirage.

Lecture à l'aveugle. Dix agents par audit lisent leur part « comme un juriste », sur le texte de production : l'article, ses versions futures, ses trois liens les plus importants, et ses textes d'application ou sa base légale. Ils ne consultent pas le registre avant de qualifier un article.

Verdicts. Chaque article est classé :

— **G** (grossier) : un juriste le remarquerait et le jugerait anormal ;

— **m** (mineur) : notes fausses, rédaction maladroite mais sans effet, ou doute raisonnable ;

— **0** : rien à signaler.

Tout G ou m exige une citation exacte. Les taux sont pondérés par strate, avec des intervalles à 95 %. Les défauts sont classés en dix familles :

F1	La loi supprime une formalité ou une obligation, mais un décret ou une annexe l'organise encore.
F2	Une sanction survit à l'obligation qu'elle sanctionne.
F3	Renvoi mort, décalé ou erroné.
F4	Une version future publiée, sans proposition, rétablit l'ancienne règle ; ou une abrogation affirmée à tort.
F5	Contradiction entre deux dispositions (hors F1).
F6	Transition absente ou fautive (rétroactivité, perte de droits acquis).
F7	Texte défectueux (tronqué, numérotation cassée, tableau amputé).
F8	Contraire à une orientation déclarée (impôt ou formalité recréés, faveur supprimée sans décision).
F9	Risque de droit supérieur (Constitution, droit de l'Union), toujours « à confirmer ».
F10	Notes ou motifs seulement (toujours mineur).

Table 4 – Familles de défauts utilisées par les auditeurs et les balayages.

Balayages par famille. Après chaque audit, nous avons transformé ses défauts grossiers en générateurs mécaniques de pistes, puis balayé tout le corpus. Exemples :

— un décret qui cite une loi abrogée ;

— une sanction qui vise un article supprimé ;

— un renvoi au n-ième alinéa d'un article qu'une proposition ou une version future a décalé ;

— une version actuelle dotée d'une proposition dont la version publiée suivante n'en a pas ;

— un décret qui emploie encore les mots distinctifs de ce que sa loi a retiré ;

— un chapitre dont seule une partie des articles est abrogée.

Une piste n'est pas un constat. Chaque piste est qualifiée par un agent qui lit les textes en entier : faux positif, déjà réglé, G ou m. Une correction est rédigée pour chaque G confirmé.

Référence. Pour savoir si un taux résiduel est bon ou mauvais, nous avons mené le même audit sur le texte *officiel* des mêmes 1 879 articles, dans les mêmes paquets, avec le même critère. Un mode « source seule » de l'outil de lecture masquait les propositions, motifs et notes du projet, et les paquets n'indiquaient pas si un article avait été réécrit. Les défauts vus d'un seul côté ont ensuite été vérifiés dans les deux textes par d'autres agents (§7.3).

Lecture systématique. Enfin, nous avons lu chaque article réécrit du CGI et de ses annexes, là où les audits montraient les taux les plus élevés. Les 2 740 articles non encore audités ont été regroupés par section, pour que chaque lecteur voie un chapitre entier. Ils ont été répartis en 132 paquets d'environ 21 articles. Chaque lecteur qualifie chaque article et rédige les corrections de ses défauts grossiers.

7 Résultats

7.1 Corrections appliquées

En six jours, la troisième passe a appliqué **1 285 lignes de correction sur 1 211 articles distincts** :

— 1 028 remplacements de propositions existantes ;

— 257 propositions nouvelles sur des versions futures publiées, qui auraient sinon rétabli le texte d'avant la réforme à leur entrée en vigueur.

Chaque ligne a été validée par le validateur du projet et archivée avec ses empreintes avant et après. Les 321 tests du projet passent après chaque tour. Le tableau 5 détaille les lignes par origine.

Origine des corrections	Pistes ou objections	Lignes appliquées
Objections P0/P1 et premières issues GitHub	86 objections	395
Objections P2	157 objections	201
Balayage 1 (renvois morts, versions futures)	1 127 pistes → 154 G	145
Balayage 2 (la loi retire, le décret garde)	1 117 pistes → 33 G	36
Défauts des audits 1 à 3, pilote « notes », issues suivantes	–	≈ 90
Tour 4 (audit 4 et balayage)	918 pistes → 45 G	64
Tour 5 (audit 5 et balayage fiscal)	548 pistes → 114 G	97
Tour 6 (audit 6 et chapitres entiers)	365 pistes → 25 G	110
Lecture systématique, CGI et annexes	2 740 articles → 96 G	81
Défauts de l'échantillon apparié encore présents	52 articles → 28 G	27
Défauts du premier nouvel échantillon encore présents	28 articles → 28 G	36

Table 5 – Corrections appliquées par la troisième passe, par origine. Les nombres viennent des rapports de chaque tour ; la ligne « ≈ » regroupe de petits ensembles de corrections.

7.2 Taux de défauts résiduel

Les auditeurs ont aussi relevé des risques de droit supérieur (F9), publiés dans les verdicts ; nous ne les qualifions pas, car cela exige une analyse juridique que la chaîne ne fait pas.

Environ 3,4 % des articles (intervalle à 95 % de 2,6 à 4,2 %) portent encore un défaut grossier (tableau 6, figure 2). Autrement dit, un juriste qui lit 20 articles de sa matière a à peu près une chance sur deux de tomber sur au moins un défaut.

Le taux ne baisse pas de façon mesurable d'un tour à l'autre, alors que chaque tour corrige 50 à 110 articles. C'est attendu. Si environ 1 000 articles sont défectueux, en corriger 100 abaisse

Audit (état du texte)	Échantillon	G	Taux G	G ou m
1 (après corrections P0/P1)	309	12	4,0 % ± 2,2	21,1 %
2 (après balayage 1)	314	9	2,9 % ± 1,9	22,1 %
3 (après balayage 2)	314	12	3,8 % ± 2,1	17,7 %
4 (après objections P2)	314	8	2,5 % ± 1,7	14,6 %
5 (après tour 4)	314	10	3,2 % ± 1,9	22,6 %
6 (après tour 5)	314	13	4,1 % ± 2,2	15,3 %
Ensemble, audits 1 à 6	1 879	64	**3,4 % ± 0,8**	
7 (nouvel échantillon, texte actuel)	632	15	2,4 % ± 1,2	20,7 %
8 (second nouvel échantillon, texte actuel)	632	9	1,4 % ± 0,9	12,3 %

TABLE 6 – Huit audits aléatoires sur des échantillons disjoints, menés à l'aveugle (verdicts bruts). Chaque échantillon exclut tous les articles déjà lus. Les audits 7 et 8 sont le côté « texte réécrit » des audits appariés sur de nouveaux échantillons (§7.4) ; leurs auditeurs savaient explicitement qu'un défaut hérité du texte officiel compte. L'audit 8 a tourné sur un autre modèle (Table 5.1).

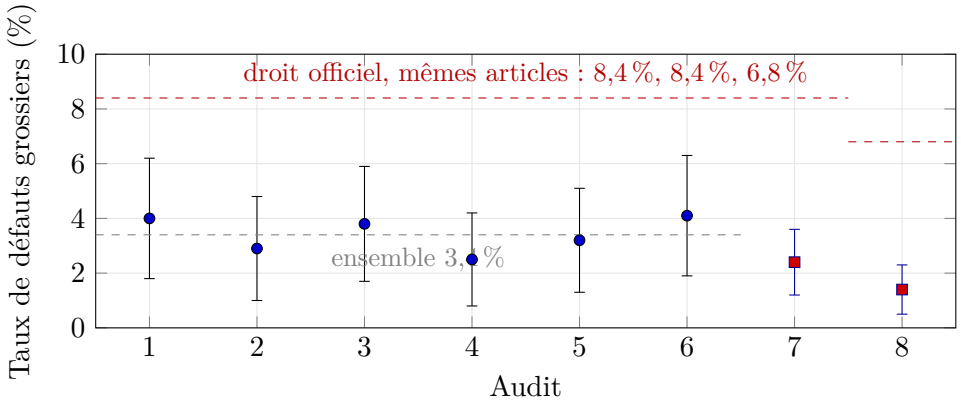


FIGURE 2 – Taux de défauts grossiers mesuré à chaque audit, avec intervalles à 95 %. Aucune baisse n'est détectable d'un tour à l'autre. La ligne rouge est le même audit mené sur le texte officiel des mêmes articles ; 8,4 % sur les deux premiers échantillons appariés et 6,8 % sur le troisième (verdicts bruts, avant vérification). Les carrés sont les audits 7 et 8, sur des nouveaux échantillons du texte actuel.

le taux d'environ 0,3 point, bien en dessous de ce qu'un audit de 314 articles peut détecter (± 2 points).

La composition des défauts, elle, a changé :

— après le premier balayage, les renvois morts (F3) ont reculé ;

— les contradictions entre deux propositions (F5) sont passées au premier plan ;

— les audits suivants se sont concentrés sur les annexes fiscales.

Selon les audits, la moitié à trois quarts des défauts grossiers trouvés étaient inconnus du registre.

7.3 Référence : le droit officiel, mêmes articles

Un taux de 3,4 % est-il bon ou mauvais ? Nous avons audité le texte officiel des mêmes 1 879 articles avec la même méthode (§6).

Verdicts bruts. Les auditeurs IA ont trouvé un défaut grossier dans 158 articles officiels (8,4 % ± 1,3), contre 64 dans les audits du projet (3,4 % ± 0,8). Seuls 24 articles ont été signalés des deux côtés. La plupart des défauts officiels sont des renvois morts ou périmés (famille F3, 124 sur 158) : articles abrogés depuis des années, organismes renommés, codes recodifiés.

Vérifier les défauts contestés. La comparaison brute ne suffit pas. Sur les 966 articles que le projet a maintenus sans changement, le texte est identique des deux côtés ; pourtant, les auditeurs du texte officiel en ont signalé 30 et ceux du projet 15. Soit les deux groupes d'auditeurs n'étaient pas aussi sévères, soit les auditeurs du projet ont minoré les défauts hérités de la source.

D'autres agents ont donc vérifié chacun des 174 défauts vus d'un seul côté, dans les deux textes, en répondant à trois questions : le défaut est-il présent dans le texte officiel ? dans le texte proposé ? est-il vraiment grossier ?

		Droit officiel		Droit réécrit	
Mêmes articles, après vérification	Articles	G	Taux	G	Taux
Tous	1 879	131	7,0 % ± 1,2	86	**4,6 % ± 0,9**
Réécrits par le projet	913	108	11,8 %	64	7,0 %
Maintenus sans changement (témoin)	966	23	2,4 %	22	2,3 %
Défauts du droit officiel réparés par la réécriture					77
Défauts introduits par la réécriture					32
Test apparié (McNemar, exact)					$p \approx 2 \times 10^{-5}$

TABLE 7 – Défauts grossiers du droit officiel et du droit réécrit, sur les mêmes 1 879 articles tirés au hasard, après vérification de tout défaut vu d'un seul côté. Les chiffres du projet sont ceux de chaque audit, à sa date.

Résultat. Après vérification, les articles maintenus, dont le texte est le même des deux côtés, présentent le même taux (23 et 22 défauts). La vérification semble donc effacer l'écart de sévérité. Sur cette base (tableau 7) :

— le droit réécrit compte **34 % de défauts grossiers en moins** que le droit officiel qu'il remplace (IC à 95 % : 19 à 47 %) : 4,6 % contre 7,0 % ;

— parmi les articles réécrits, le taux passe de 11,8 % à 7,0 % ;

— pour chaque défaut introduit par la réécriture, plus de deux défauts du droit officiel ont été réparés (77 contre 32).

Une exception ressort. Dans la partie législative du CGI, l'échantillon compte plus de défauts vérifiés après la réécriture qu'avant (9 contre 3) : réformer l'impôt sur les sociétés et l'impôt sur le revenu crée des incohérences plus vite qu'il n'en supprime. C'est là que s'est concentrée la lecture systématique (§7).

Les chiffres du projet sont ceux de chaque audit, à sa date. Tout défaut grossier de cet échantillon encore présent dans le texte réécrit a depuis été corrigé (27 lignes, tableau 5). Cet échantillon ne peut donc plus mesurer le texte actuel sans biais : nous en avons tiré un nouveau.

7.4 Deux audits appariés sur de nouveaux échantillons du texte actuel

Nous avons tiré 632 nouveaux articles, jamais tirés auparavant, avec les mêmes strates et une allocation doublée. Chacun a été audité deux fois, à l'aveugle : une fois sur le texte réécrit actuel (audit 7), une fois sur le texte officiel, par 20 agents de chaque côté. Les auditeurs du texte réécrit savaient explicitement qu'un défaut hérité du texte officiel compte, ce qui rend ce

côté plus sévère que dans les audits 1 à 6. Les 52 défauts vus d'un seul côté ont de nouveau été vérifiés dans les deux textes.

Les 28 défauts encore présents dans cet échantillon ont ensuite été corrigés (36 lignes). L'audit a été répliqué sur un autre nouvel échantillon de 632 articles (audit 8), avec le même protocole et un autre modèle (Claude Fable 5.1 au lieu de Claude Opus 5.5) ; 44 défauts vus d'un seul côté ont été vérifiés. L'audit 8 a été lu pendant que ces corrections étaient appliquées, mais l'archive des corrections montre qu'aucune des 63 lignes appliquées depuis le tirage du premier nouvel échantillon n'a touché un article de l'audit 8 avant sa lecture ; la seule qui l'a fait ensuite a été appliquée 28 minutes après le dernier verdict de l'audit 8. Les deux audits mesurent donc le même état du corpus sur des articles disjoints, ce qui justifie de les cumuler. Les 16 défauts trouvés par l'audit 8 n'ont pas été corrigés : cet échantillon reste une mesure intacte.

		Droit officiel		Droit réécrit, à l'audit		Réparés /
Nouveaux échantillons, après vérification	Articles	G	Taux	G	Taux	introduits
Audit 7 (Opus 5.5)	632	49	7,8 % ± 2,1	28	4,4 % ± 1,6	28 / 7
Audit 8 (Fable 5.1)	632	46	7,3 % ± 2,0	16	2,5 % ± 1,2	32 / 2
Ensemble	1 264	95	7,5 % ± 1,5	44	**3,5 % ± 1,0**	60 / 9
réécrits par le projet	581	84	14,5 %	35	6,0 %	
maintenus (témoin)	683	11	1,6 %	9	1,3 %	
Test apparié sur les deux échantillons (McNemar, exact)						$p \approx 2 \times 10^{-10}$

TABLE 8 – Défauts grossiers du droit officiel et du droit réécrit à la date des audits, sur deux nouveaux échantillons de 632 articles chacun, jamais tirés auparavant, après vérification de tout défaut vu d'un seul côté.

Les nouveaux échantillons confirment et précisent la comparaison appariée (tableau 8) :

— le droit réécrit compte **54 % de défauts grossiers en moins** que le droit officiel (IC à 95 % : 40 à 64 %) : 3,5 % contre 7,5 % sur 1 264 articles ;

— parmi les articles réécrits, le taux passe de 14,5 % à 6,0 %, soit 58 % de moins ;

— la réécriture a réparé environ sept défauts du droit officiel pour chaque défaut introduit (60 contre 9), contre deux pour un dans le premier échantillon apparié ;

— le témoin concorde : les articles maintenus, dont le texte est identique des deux côtés, présentent 11 et 9 défauts ;

— les deux modèles concordent sur le texte officiel (7,8 et 7,3 %) ; sur le texte réécrit, Fable trouve moins de défauts (2,5 contre 4,4 %), dans les intervalles ;

— pris seul, l'audit 8, le plus récent et laissé sans correction, donne environ deux tiers de défauts en moins (16 contre 46, 2,5 contre 7,3 %) ; nous gardons les 54 % cumulés comme résultat principal, parce qu'ils reposent sur deux fois plus d'articles et sur deux modèles.

Les verdicts bruts donnent 8,4 et 6,8 % pour le texte officiel, contre 2,4 et 1,4 % pour le texte réécrit. Sur les 44 défauts trouvés dans le texte réécrit, 35 étaient hérités du droit officiel et 9 introduits par la réécriture. Les 28 de l'audit 7 ont depuis été corrigés ; les 16 de l'audit 8 restent ouverts. Le code fiscal, exception du premier échantillon apparié, compte ici 3 défauts officiels et 5 défauts réécrits sur 96 articles.

7.5 Balayages : rendement et plateau

Le rendement des balayages a baissé à mesure que chaque famille s'épuisait. Le balayage « la loi retire, le décret garde » a donné 3 % de G par piste, contre 14 % pour le premier balayage.

Seule la requalification a fait remonter le rendement : relues au seuil de l'audit, 56 des 166 pistes jugées mineures auparavant se sont révélées grossières.

Un pilote sur 250 articles dont les notes de revue annonçaient une coordination ouverte a montré que 60 % de ces notes étaient simplement périmées. Son taux de G était de 4,8 %, à peine plus que la lecture au hasard : le balayage complet n'a donc pas été lancé.

7.6 Lecture systématique du code fiscal

La lecture, chapitre par chapitre, des 2 740 articles réécrits du CGI et de ses annexes a donné :

— 96 défauts grossiers (3,5 %) ;

— 383 défauts mineurs ;

— 2 261 articles sans rien à signaler.

Ce taux de 3,5 % est bien inférieur aux 9 à 12 % que suggéraient les audits pour ces strates. Ces estimations reposaient sur de petits échantillons (76 et 128 articles), et les tours 4 à 6 s'étaient concentrés sur les annexes fiscales. Nous ne pouvons pas exclure qu'un lecteur qui parcourt un chapitre entier soit un peu moins strict qu'un auditeur à l'aveugle.

Sur les 96 défauts, 86 sont corrigés (81 lignes, dont 16 demandées entre groupes). Dix restent ouverts. Neuf sont des réformes de TVA écrites dans des subdivisions du CGI que l'ordonnance n° 2025-1247 transfère au CIBS le 1er janvier 2027 : ces réformes seraient donc sans effet, et le CIBS est hors du corpus. Le dixième est un arbitrage politique laissé à l'auteur.

La lecture a consommé environ 30 millions de jetons (hors lectures de cache), soit environ 11 000 jetons par article.

7.7 Coût

Ce qui a été payé.

— **Passes de rédaction (Codex d'OpenAI) :** environ 1 000 dollars US de crédits API, plus un abonnement ChatGPT Pro (200 dollars par mois).

— **Troisième passe (Claude Code) :** un abonnement Claude Max (200 dollars par mois), sans crédits API facturés. Sa consommation enregistrée sur six jours est de 32 046 requêtes au modèle, 29,5 millions de jetons de sortie, 5,1 milliards de jetons lus en cache et 135 millions de jetons écrits en cache : environ **2 500 dollars** aux tarifs de l'affichage des coûts de Claude Code, ou environ 4 100 dollars aux prix publics de l'API.

En comptant un mois de chaque abonnement, la dépense réelle du projet a été d'environ **1 400 dollars**, moins de 5 centimes par article. Au prix de l'API, elle aurait été de 3 500 à 5 100 dollars, soit 12 à 17 centimes par article. Ces montants n'incluent pas le temps humain : quelques jours de direction et d'arbitrage d'une personne.

Ce que le même travail coûterait avec des juristes. C'est un ordre de grandeur, pas une mesure, et il dépend de ses hypothèses ; nous donnons donc deux scénarios (tableau 9). Tous deux ne comptent que le travail effectivement accompli ici : 14 115 réécritures et 16 199 maintiens motivés en première passe, 30 314 relectures en seconde, et environ 12 500 lectures d'audit et de balayage, 1 943 alertes qualifiées et 1 285 corrections en troisième. Le scénario *prudent* suppose 2 heures par article réécrit, une demi-heure par lecture et une heure et demie par correction. Le scénario *réaliste* suppose 6 heures par article réécrit, ce qui laisse le temps d'en vérifier les renvois et les textes d'application, 1 heure par article maintenu et par relecture de cohérence, une demi-heure par lecture d'audit, 1 heure par alerte et 3 heures par correction. Les coûts retiennent 100 euros de l'heure pour des rédacteurs juridiques internes, 250 euros pour un tarif moyen de cabinet, et 1,10 dollar pour un euro.

			Fois le coût du travail de l'IA	
Scénario	Heures	Coût juristes	prix de l'API	dépense réelle
Prudent	60 000	6 à 15 M€	1 300 à 4 700	4 700 à 11 800
Réaliste	143 000	14 à 36 M€	3 100 à 11 300	11 000 à 28 000

TABLE 9 – Ordre de grandeur du coût du même travail par des juristes. 60 000 heures représentent 35 à 40 années de travail ; 143 000 heures, environ 85. Le travail de l'IA a coûté 3 500 à 5 100 dollars au prix de l'API et environ 1 400 dollars en dépense réelle.

Selon le scénario, le travail de l'IA est donc **2 500 à 10 000 fois moins cher** : environ 2 500 fois au milieu du scénario prudent, et environ 10 000 fois dans le scénario réaliste au tarif des cabinets ou rapporté à la dépense réelle. La comparaison porte sur le coût, pas sur la qualité : le résultat de ce projet attend encore une relecture par des juristes, qu'aucune mesure par l'IA ne remplace.

7.8 Exemples de défauts

Les exemples suivants, tous corrigés sauf mention contraire, montrent le type d'erreurs que produit la rédaction par IA et que la revue par IA peut détecter :

— *Recréer un impôt que le projet supprime.* L'inventaire avait retenu une version de l'article 1609 *quinvicies* du CGI jamais entrée en vigueur. Sa proposition rétablissait la contribution supplémentaire à l'apprentissage, que l'article L6242-1 proposé du code du travail supprime.

— *Un taux « réduit » supérieur au taux normal.* Après la réforme de l'impôt sur les sociétés, le taux réduit de 24 % des organismes sans but lucratif (CGI 219 *bis*) dépassait le nouveau taux normal de 20 %.

— *Des chapitres à moitié abrogés.* Dans l'annexe II du CGI, un tour de correction a abrogé une partie des articles sur les centres de gestion agréés, dont la base légale (CGI 1649 *quater* C à O) avait été abrogée en 2025. Les articles voisins organisaient encore la procédure d'agrément. L'audit suivant l'a relevé, et le chapitre a ensuite été traité en entier.

— *Des versions futures qui défont la réforme.* Une adaptation à Mayotte prévue pour 2028 (CSS L759-23) appliquait « dans la rédaction suivante » un article réécrit par le projet, rétablissant ainsi la règle que le projet supprime.

— *Un décret contre sa loi.* Un décret fiscal proposé supprimait l'accréditation préalable des représentants fiscaux, alors que la loi (CGI 1671) l'exigeait encore. La correction cohérente aligne la loi, au lieu de rétablir une formalité.

— *Une réduction cohérente qui retire une protection (corrigé après signalement).* La réécriture de L600-8 du code de l'urbanisme supprimait la sanction des transactions qui monnaient le retrait d'un recours contre un permis (ordonnance n° 2013-638), sans casser aucun renvoi. Aucun audit ne l'avait relevé ; le troisième auteur l'a signalé (issue #17), et le texte en vigueur a été rétabli.

8 Discussion

Ce que les agents d'IA font bien. À cette échelle, les agents sont des lecteurs infatigables, complets et au mot près. Ils reproduisent des articles entiers, y compris des tableaux de plusieurs centaines de milliers de caractères. Ils suivent les renvois à travers neuf recueils et de nombreuses versions, et ils gardent des citations exactes. Avec des modifications typées et des écritures contrôlées, cela a permis de réécrire puis de réparer un corpus qu'aucune personne ne pourrait

relire en une semaine. Le travail est aussi entièrement vérifiable : chaque changement est archivé avec son état antérieur et son motif.

Ce qu'ils font mal.

- *La frontière du corpus.* Beaucoup de défauts impliquent un texte qui n'était pas fourni : le CIBS, des lois non codifiées, des arrêtés. Un agent ne peut que les signaler comme réserves documentaires, et ne doit pas deviner.
- *Le temps.* Les textes juridiques ont des versions futures programmées. Une réforme écrite sur une version qui prend fin avant que la réforme puisse s'appliquer est sans effet. Une version future sans proposition rétablit sans bruit l'ancienne règle.
- *Une cohérence locale sans cohérence globale.* Une modification isolée est valide, mais ses voisines restent incohérentes. L'un de nos propres tours de correction a créé exactement un tel chapitre à moitié abrogé. Nous l'avons corrigé en traitant les chapitres en entier, et en lançant un contrôle de régression après chaque application : tout article qui cite encore un article abrogé au cours du tour.
- *La calibration.* Les lecteurs ne séparent pas grossier et mineur avec la même sévérité. Les premiers balayages avaient classé des renvois morts comme mineurs. Requalifiés au seuil de l'audit, un tiers d'entre eux sont devenus des défauts grossiers.

La mesure change la discussion. Sans les audits aléatoires, le nombre de corrections, plus de 1 200, aurait laissé croire à un progrès régulier. Les audits montrent un plateau autour de 3 à 4 %, et ils l'expliquent. Les balayages ciblés aident, mais les défauts restants sont dispersés. Seule une lecture systématique peut faire nettement baisser le taux. La référence appariée transforme ce plateau en résultat : le droit en vigueur n'est pas exempt de défauts non plus, et la réécriture, avec ses erreurs résiduelles, est mesurablement plus cohérente que les textes qu'elle remplace. Un taux de défauts publié, reproductible, assorti d'un intervalle et comparé à une référence nous semble le minimum pour toute affirmation sur une législation rédigée par IA.

Contradictions et politique. Tenir la red team à l'écart des choix politiques a été plus difficile que prévu. Beaucoup de contradictions apparentes ont deux résolutions cohérentes : supprimer une faveur ou l'étendre, rétablir une formalité ou en effacer le reliquat. Nous avons tranché par un critère d'alignement explicite et publié (§5), et nous avons renvoyé les vrais arbitrages à l'auteur. Un autre programme changerait le critère, pas la méthode.

Portabilité et neutralité. Deux arguments plaident pour la portabilité. D'abord, la plupart des défauts mesurés (renvois morts, versions futures, décrets non alignés, contradictions) ne dépendent pas du sens de la réforme : ils apparaîtraient avec n'importe quel programme qui modifie beaucoup d'articles. Ensuite, l'évaluation est appliquée au droit officiel sans aucun programme. Deux arguments plaident pour la prudence. Les consignes de rédaction et le critère d'alignement portent l'orientation du programme ; et les modèles peuvent traiter différemment des réformes qui vont dans des sens différents. Il est donc raisonnable d'attendre une détection des défauts comparable d'un programme à l'autre. Une expérience comparative le confirmerait : appliquer la même chaîne à deux programmes contrastés au moins, avec le même protocole d'évaluation, et comparer les taux de défauts. Nous invitons à la mener.

La relecture par des experts. Les résultats sont produits par l'IA seule, par choix, et aucun juriste ne les a encore validés. La chaîne rend la relecture par des experts *moins coûteuse*, pas inutile : chaque article est livré avec sa source, son motif, ses notes, ses objections et sa trace

d'audit. Le suivi public des issues s'est révélé le canal le plus efficace. Neuf des onze premières issues externes visaient un vrai défaut.

9 Limites

— Les résultats sont mesurés par l'IA, par choix. Les verdicts d'audit sont des jugements de modèles et peuvent se tromper dans les deux sens ; leur justesse est ouverte à la vérification par des experts, que nous invitons.

— Une suppression cohérente d'une garantie, voulue par le programme, n'est comptée comme défaut que si l'auditeur la juge anormale ; les risques F9 ne font pas l'objet d'un taux publié.

— La sévérité des auditeurs varie. Sur des textes identiques, deux groupes d'auditeurs ont différé d'un facteur deux avant vérification (§7.3). Le taux d'un audit isolé est à lire avec cette réserve. L'audit 8 a tourné sur un autre modèle que les audits 1 à 7 ; il concorde sur le texte officiel mais trouve moins de défauts dans le texte réécrit, et un écart de sévérité entre modèles ne peut être exclu.

— Auto-évaluation partielle. Le modèle qui a corrigé (Claude Opus 5.5) a aussi mené les audits 1 à 7, et les deux modèles d'audit viennent du même fournisseur ; un audit croisé du même échantillon par un modèle d'un autre fournisseur reste à faire, et les verdicts et les graines publiés permettent à quiconque de le mener.

— Les coûts « juristes » sont des ordres de grandeur construits sur deux jeux d'hypothèses explicites, ni un devis ni une mesure.

— Un seul programme a été mis en œuvre ; l'expérience comparative avec d'autres programmes reste à mener, et les consignes de rédaction et le critère d'alignement doivent être réécrits pour chaque programme (tableau 3).

— Le corpus est figé au 18 octobre 2026, et les textes hors des neuf recueils ne sont pas réécrits.

— La jurisprudence n'est pas prise en compte. Rédaction et audits lisent les codes, pas les décisions qui les interprètent : une réécriture peut donc s'écarter sans le vouloir d'une interprétation établie, et un audit peut manquer un défaut déjà relevé par les juges.

— Des échantillons d'audit d'environ 314 articles ne détectent que des écarts d'environ ± 2 points ; les taux par strate sont donc imprécis.

— Les modèles de rédaction et le modèle de revue viennent de fournisseurs différents, ce qui limite les angles morts communs sans les supprimer.

— Les coûts sont donnés tels que payés, avec une estimation en équivalent API pour la troisième passe. Ils n'incluent pas le temps humain et ne constituent pas une mesure de productivité.

— Les effets économiques et budgétaires de la réforme sortent du champ de cet article.

10 Conclusion et travaux futurs

Nous avons réécrit de bout en bout cinq codes français et les quatre annexes du CGI avec des agents d'IA, éprouvé le résultat par une red team distincte, et mesuré ce qui reste faux. Mesuré contre le droit officiel sur les mêmes articles, chaque défaut contesté vérifié, le droit réécrit compte 34 % de défauts grossiers en moins sur 1 879 articles à la date des audits, et **54 % de moins** sur deux nouveaux échantillons de 1 264 articles tirés en fin de travail (3,5 % contre 7,5 %). Les quatre cinquièmes des défauts trouvés sont hérités du droit en vigueur. Le projet

a coûté environ 1 400 dollars, 2 500 à 10 000 fois moins que le même travail par des juristes. Toute la trace est publique.

Prochaines étapes :

— la lecture systématique des autres articles réécrits : construction-habitation et sécurité sociale (environ 5 500), puis travail et urbanisme (environ 5 900) ;

— l'intégration du CIBS au corpus ;

— dans une seconde version, la prise en compte de la jurisprudence : relier chaque article aux décisions du Conseil constitutionnel, du Conseil d'État et de la Cour de cassation qui l'interprètent (données ouvertes de la DILA et API Judilibre), pour que les réécritures respectent les interprétations établies et que les audits les vérifient ;

— la validation par des juristes praticiens, en commençant par les objections et arbitrages ouverts ;

— une expérience comparative : appliquer la même chaîne à deux programmes contrastés au moins, avec le même protocole d'évaluation.

Vers une chaîne configurable par programme. Le tableau 10 décrit la chaîne que ce travail amorce, et sépare ce qui est démontré ici de ce qui reste à construire.

Étape	État dans ce travail
1. Ingérer le programme d'un parti	À construire : fait à la main, sous la direction de l'auteur.
2. Le convertir en spécifications structurées	En partie : fichiers de paramétrage explicites, rédigés à la main.
3. Identifier les lois, règlements, renvois et dépendances concernés	Démontré sur cinq codes et quatre annexes ; hors corpus (CIBS, lois non codifiées) à étendre.
4. Proposer les modifications dans tout le corpus touché	Démontré : 14 115 articles réécrits.
5. Détecter contradictions, effets non voulus et ambiguïtés	Démontré et mesuré : red team, registre, audits.
6. Produire une proposition versionnée et auditable, article par article	Démontré : dépôt public, lecteur, états antérieurs archivés.
7. Estimer l'effort et lister les questions qui exigent un jugement humain	En partie : coûts mesurés, arbitrages renvoyés à l'auteur.

Table 10 – Une chaîne configurable par programme : ce qui est démontré et ce qui reste à faire.

L'échéance de 2027 fournit un cas d'usage immédiat, mais l'objectif scientifique dépasse toute élection et tout parti : examiner si l'IA peut faire de la réforme législative, aujourd'hui manuelle, coûteuse et fragmentée, un processus reproductible, auditable et configurable par programme. À terme, des programmes concurrents pourraient ainsi être traduits en propositions législatives comparables et techniquement cohérentes, ce qui rendrait les conséquences pratiques des choix politiques plus faciles à examiner et à débattre. Au-delà de ce cas d'étude, la méthode est un modèle : un paramétrage explicite du programme, une rédaction complète, des écritures contrôlées, une red team distincte et une mesure honnête. Nous espérons qu'elle rende le droit plus lisible, et qu'elle donne à chacun un moyen concret de vérifier la cohérence d'une réforme proposée.

Appel à contributions

Ces textes ne sont pas infaillibles : environ 3 % des articles portent encore un défaut grossier, et aucun juriste ne les a validés. Tout est public :

`https://github.com/AlexMasmej/liberer-la-france`

Nous invitons juristes, universitaires, fonctionnaires, citoyens et toute personne intéressée à aider à consolider ce code. Pour signaler un défaut, ouvrez une issue avec :

— l'article (code, numéro et identifiant `LEGIARTI`) ;

— le passage exact ;

— le problème et, si possible, une correction proposée.

Chaque issue est triée par rapport au registre. Les contradictions et les failles sont corrigées, et l'issue est close avec un lien vers le commit. Les demandes qui changeraient une orientation politique sont expliquées et closes. Les demandes de fusion sont aussi bienvenues.

Nous invitons aussi chercheurs, juristes, organisations politiques et contributeurs indépendants à adapter la chaîne à d'autres programmes : proposer d'autres configurations de politiques, écrire une représentation structurée du programme d'autres partis, et vérifier si la chaîne produit des modifications cohérentes sous d'autres hypothèses. L'ambition n'est pas de promouvoir un candidat, mais de construire une infrastructure réutilisable au service du travail législatif de n'importe quel futur gouvernement.

Disponibilité des données et du code

Le corpus réécrit, les sources officielles, les politiques, les lots, les rapports et le registre de la troisième passe, les échantillons et verdicts d'audit, et les outils de balayage et de lecture sont publics sur `https://github.com/AlexMasmej/liberer-la-france`. Un lecteur comparatif et des téléchargements complets sont disponibles sur `https://www.libererlaretraite.com/corpus/` et `https://www.libererlaretraite.com/telechargements/`.

Usage de l'IA

Des systèmes d'IA ont effectué l'essentiel du travail de rédaction, de revue et de correction décrit ici, sous la direction et l'arbitrage d'humains. Ce manuscrit a été rédigé avec l'aide de Claude (Anthropic) à partir des archives du projet, puis relu par les auteurs.

Contributions des auteurs

Les contributions sont données selon la taxonomie CRediT.

— **Alexandre Masmejean :** Conceptualisation (a conçu le projet) ; Méthodologie (a fixé le paramétrage du programme) ; Investigation (a conduit les passes de rédaction) ; Supervision et Administration du projet (a dirigé le projet et arbitré tous les choix politiques) ; Rédaction – révision et édition.

— **Nathalie Gouailhardou :** Conceptualisation (a proposé de comparer systématiquement les taux d'erreur des textes juridiques officiels et de leurs équivalents réécrits par l'IA, l'évaluation comparative des §7.3 et §7.4) ; Méthodologie (a relevé qu'évaluer différemment les textes officiels et réécrits introduirait des facteurs de confusion, et a proposé d'appliquer aux deux la même méthode et les mêmes critères d'évaluation, ce qui a établi une référence cohérente pour une comparaison valide).

— **Kevin Primicerio :** Investigation (revue externe indépendante des codes publiés avec ses propres agents d'IA) ; Validation (issues et tests d'acceptation, triés et en partie intégrés) ; Rédaction – révision et édition.

Tous les auteurs ont lu et approuvé la version finale du manuscrit.

Remerciements

Nous remercions Rand Hindi, dont l'exemple a inspiré l'approche de « red teaming » de la troisième passe. Nous remercions Emmanuel Masmejean pour sa relecture attentive de la version française. Nous remercions toutes celles et ceux qui ont lu, critiqué et partagé le fil initial.

Références

[1] Constitution du 4 octobre 1958, articles 6 et 7 (élection du Président de la République au suffrage universel direct, pour cinq ans).

[2] Conseil constitutionnel, Décision n° 99-421 DC du 16 décembre 1999, *Loi portant habilitation du Gouvernement à procéder, par ordonnances, à l'adoption de la partie législative de certains codes*.

[3] Conseil d'État, *Simplification et qualité du droit*, Étude annuelle 2016, La Documentation française, 2016.

[4] A. Masmejean (Alex Masmej, `@AlexMasmej`), Fil publié sur X, 19 octobre 2026, `https://x.com/AlexMasmej/status/2112088220804722917` (chiffres d'audience relevés le 31 octobre 2026).

[5] D. Lisnard et Nouvelle Énergie, Programme pour l'élection présidentielle de 2027, `https://www.unenouvelleenergie.fr/`.

[6] Direction de l'information légale et administrative (DILA), LEGI : codes, lois et règlements consolidés, `https://www.data.gouv.fr/datasets/legi-codes-lois-et-reglements-consolides`.

[7] N. Guha et al., LegalBench : A collaboratively built benchmark for measuring legal reasoning in large language models, *NeurIPS Datasets and Benchmarks*, 2023. arXiv :2308.11462.

[8] D. Merigoux, N. Chataing et J. Protzenko, Catala : A programming language for the law, *Proceedings of the ACM on Programming Languages* 5(ICFP), 2021. arXiv :2103.03198.

[9] Observatoire de l'innovation dans le secteur public de l'OCDE, *Cracking the Code : Rulemaking for Humans and Machines*, OCDE, 2020.

[10] D. Ganguli et al., Red teaming language models to reduce harms : Methods, scaling behaviors, and lessons learned, arXiv :2209.07858, 2022.