Le code source du droit : des agents d'IA réécrivent et vérifient cinq grands codes français

Alexandre Masmejean* Indépendant
Kevin Primicerio Indépendant
Nathalie Gouailhardou Indépendante

31 octobre 2026

Résumé

Le droit français est difficile à lire : une même règle se répartit entre une loi, ses décrets d'application, les annexes fiscales et des versions consolidées futures, qui se contredisent souvent. Des agents d'IA réécrivent, puis auditent de façon contradictoire, cinq grands codes français complets (code du travail, code général des impôts et ses quatre annexes, codes de la sécurité sociale, de l'urbanisme et de la construction et de l'habitation) : 30 317 entrées d'articles issues de la base officielle LEGI au 18 octobre 2026. Deux passes de rédaction ont produit 14 115 articles réécrits et 16 199 articles maintenus avec justification. Une troisième passe, en « red team » indépendante, a tenu un registre d'objections, appliqué environ 1 290 corrections et mesuré la fiabilité par six audits aléatoires stratifiés à l'aveugle. Sur deux échantillons frais totalisant 1 264 articles, audités à l'aveugle sur les deux textes et chaque défaut contesté vérifié, des auditeurs IA trouvent un défaut grossier dans 7,5 % ± 1,5 des textes officiels, contre 3,5 % ± 1,0 du droit réécrit actuel (test apparié, $p \approx 2 \times 10^{-10}$) : 60 défauts officiels réparés, surtout des renvois morts, pour 9 introduits. Une comparaison sur 1 879 articles concorde (7,0 contre 4,6 %). Les balayages ciblés corrigent une famille à la fois sans faire bouger le taux mesuré ; une lecture systématique des 2 740 articles fiscaux réécrits a trouvé 96 défauts grossiers et en a corrigé 86. Le projet a coûté environ 1 400 dollars ; le même travail par des juristes se chiffrerait en millions d'euros. Les choix de fond suivent le programme 2027 de David Lisnard, mais le projet est une initiative indépendante et la méthode est neutre quant aux choix politiques. Ces résultats, produits et mesurés par des agents d'IA seuls, sont publiés avec textes, outils et verdicts pour que juristes et citoyens les vérifient et les consolident.

1 Introduction

La lisibilité, une exigence juridique. L'accessibilité et l'intelligibilité de la loi sont, en France, un objectif de valeur constitutionnelle [1]. Le Conseil d'État critique depuis des décennies l'inflation et l'instabilité des textes [2].

Le problème n'est pas seulement le volume. Une même règle se répartit entre plusieurs textes :

— une loi (partie législative) ;

— ses décrets d'application (partie réglementaire) ;

— pour la fiscalité, les quatre annexes du CGI ;

— des versions consolidées futures, déjà publiées mais pas encore en vigueur.

Quand l'un de ces textes change et pas les autres, des contradictions apparaissent. Certaines viennent des sources officielles elles-mêmes ; d'autres naissent de la réforme.

*Auteur correspondant : alex@masmej.com. Alex Masmej sur X : https://x.com/AlexMasmej.

Origine de ce travail. Le 19 octobre 2026, le premier auteur a publié un court fil en français [3]. Il répondait à un défi public et annonçait que des agents d'IA avaient produit, en une nuit, des versions réécrites de plusieurs codes français, publiées sur cinq sites thématiques. Le fil invitait juristes, économistes, salariés et entrepreneurs à critiquer les propositions article par article.

L'accueil a été bien plus large que prévu : environ 120 000 vues, 1 190 mentions ń j'aime ż, 201 republications et 293 signets au dernier relevé. Les critiques qui ont suivi ont été plus utiles encore. Elles ont montré qu'un premier jet rapide ne suffisait pas, et qu'une démonstration crédible demandait trois choses :

(i) les codes complets, pas une sélection ;

(ii) une recherche systématique des contradictions ;

(iii) une mesure honnête de ce qui reste faux.

Cet article documente cette seconde phase, plus lente.

Objectif. Nous poursuivons deux objectifs.

— **La lisibilité.** Produire, pour chaque article du périmètre, un texte proposé complet, présenté en regard de la source officielle et accompagné d'une justification écrite.

— **Une preuve de concept pour trouver et résoudre les contradictions.** Montrer comment des agents d'IA peuvent trouver et résoudre les contradictions d'un vaste corpus juridique interconnecté, et jusqu'où.

Le second objectif est le principal intérêt scientifique. Réformer un code est simple à énoncer et difficile à faire de façon cohérente. Supprimer une obligation dans une loi n'a pas de sens si un décret, une annexe fiscale ou une version consolidée future continue de l'imposer.

Contributions.

— Une réécriture complète, versionnée et publique de neuf recueils juridiques (30 317 entrées). Sources officielles et propositions sont tenues séparées, avec un lecteur comparatif et des téléchargements (§3–§4).

— Un protocole de « red teaming » pour la législation produite par IA :

  — instantanés figés, dont tous les fichiers sont empreintés ;

  — un registre d'objections, avec priorités et natures ;

  — un réexamen sur les différences ;

  — une correction soumise à un critère d'alignement explicite ;

  — un écrivain gardé qui ne peut rien écraser sans contrôle (§5).

— Une méthode de mesure : six audits aléatoires stratifiés, menés à l'aveugle, avec une taxonomie de dix familles de défauts (F1 à F10). Le taux s'accompagne d'un intervalle de confiance, pas d'une anecdote (§6).

— Une référence appariée : le même audit mené sur le droit officiel, sur les mêmes articles. Le droit réécrit compte moins de défauts grossiers que le droit qu'il remplace : 4,6 % contre 7,0 % sur 1 879 articles à la date des audits, et 3,5 % contre 7,5 %, soit moins de la moitié, sur deux échantillons frais de 1 264 articles du texte actuel (§7.3, §7.4).

— Une comparaison de coût : environ 1 400 dollars déboursés, 3 500 à 5 100 dollars au prix de l'API, contre un ordre de grandeur de plusieurs millions d'euros pour le même travail par des juristes (§7.7).

— Des constats empiriques sur ce que les agents d'IA font bien et mal en matière de cohérence juridique (§7–§8) :

— les balayages mécaniques atteignent un plateau ;

— les tours de correction peuvent créer de nouveaux défauts ;

— une large part de l'erreur résiduelle vient de textes hors du corpus.

Des résultats produits par l'IA seule. Cet article rapporte délibérément ce que des agents d'IA ont accompli seuls. Rédaction, revue, correction et mesure ont toutes été faites par des agents d'IA, sous direction et arbitrage humains, mais sans juristes. Nous publions les résultats pour que juristes et citoyens les vérifient et les consolident (voir l'appel à contributions à la fin).

Position politique. L'orientation de fond de la réécriture est explicite et n'est pas neutre. Elle vise moins d'impôts et moins de contraintes. Elle conserve les exonérations, les dérogations favorables, les droits acquis et les transitions. Elle n'introduit jamais de formalité de remplacement.

Ces choix s'inspirent du programme 2027 de David Lisnard [4]. **Ce projet est une initiative indépendante.** Il n'est ni commandé, ni relu, ni approuvé par David Lisnard ni par son mouvement, Nouvelle Énergie, et les sites publiés le disent.

La méthode, elle, est neutre. La couche de politiques est une entrée distincte et explicite (§4.1), et la même chaîne pourrait mettre en uvre n'importe quel autre programme. La red team avait pour consigne de corriger les contradictions et les failles, *jamais* de modifier les choix politiques.

2 Travaux connexes

Les grands modèles de langage sont de plus en plus évalués sur le raisonnement juridique, par exemple avec LegalBench [6]. Les travaux qui rendent la législation lisible par machine prennent deux formes :

— des langages de programmation pour les lois, comme Catala, appliqué au droit fiscal français [7] ;

— les initiatives « rules as code » [8].

Ces deux approches formalisent fidèlement le droit existant. Notre objectif est différent : nous *réécrivons* le droit selon un programme de réforme, puis nous vérifions la cohérence du résultat.

Le « red teaming », recherche contradictoire de défaillances par une partie indépendante, est une pratique courante pour les systèmes d'IA [9]. Il est ici retourné contre une législation produite par IA.

Nous ne connaissons pas de travail antérieur qui réécrive de bout en bout des codes nationaux complets et publie un taux de défauts mesuré.

3 Corpus et périmètre

Le corpus est figé au **18 octobre 2026**. Il est construit à partir de la base officielle LEGI de la Direction de l'information légale et administrative (DILA) [5] : le stock du 13 juillet 2025, plus 466 mises à jour quotidiennes.

L'identité de travail d'un article est le couple (identifiant du code, identifiant de version `LEGIARTI`), accompagné d'une empreinte de sa source et de ses dates de validité. On ne se fie jamais au seul numéro, car les numéros sont recyclés. La base contient 135 904 versions historiques ; le périmètre couvre les 30 317 entrées en vigueur ou programmées (tableau 1).

Sont hors périmètre les textes que le corpus cite sans les contenir. Par exemple : le code monétaire et financier, le code de commerce, les lois non codifiées, les arrêtés, et le code des

Recueil	Entrées	Réécrits	Maintenus	Réserves
Code du travail	11 593	4 296	7 297	0
Code général des impôts (CGI)	2 375	1 387	988	0
Code de la sécurité sociale	7 427	3 178	4 247	2
Code de l'urbanisme	2 459	1 530	929	0
Code de la construction et de l'habitation	4 126	2 205	1 921	0
CGI, annexe I	71	42	29	0
CGI, annexe II	674	388	286	0
CGI, annexe III	1 115	799	316	0
CGI, annexe IV	477	290	186	1
Total	30 317	14 115	16 199	3

TABLE 1 – Périmètre à la fin de la seconde passe. Les articles « maintenus » sont conservés sans changement, avec une justification propre. Les trois « réserves » sont des lacunes documentaires (une figure manquante, des formulaires originaux manquants et un conflit dans la consolidation officielle) qui n'ont pas été comblées par supposition.

impositions sur les biens et services (CIBS), dans lequel une grande partie de la TVA est recodifiée au 1er janvier 2027. Cette frontière se révèle importante (§8).

4 Chaîne de rédaction (première et seconde passes)

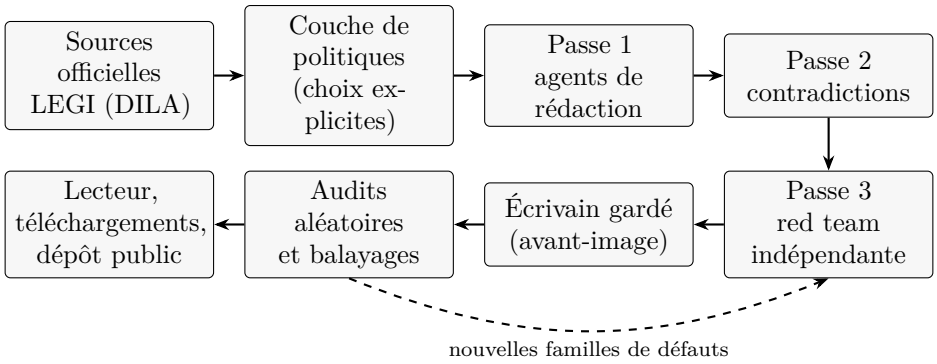


FIGURE 1 – Vue d'ensemble de la chaîne. Toute écriture passe par le même écrivain gardé ; les audits renvoient de nouvelles familles de défauts à la red team.

4.1 Couche de politiques

La figure 1 résume l'ensemble de la chaîne. Toutes les décisions de fond sont stockées comme des objets de politique explicites et versionnés, séparés du texte juridique : coordinations par domaine, résumés des sites et méthode de chiffrage net des mesures fiscales. Exemples :

— un contrat de travail unique à durée indéterminée, avec un préavis de quinze jours de chaque côté ;

— un impôt sur les sociétés déclenché par la distribution ;

— la suppression des droits de succession, les donations restant taxées ;

— la suppression des impôts de production ;

— des délais d'instruction des permis raccourcis.

Le reste de la chaîne les traite comme des entrées.

Des invariants éditoriaux s'appliquent partout :

— les sources officielles ne sont jamais écrasées ;

— aucun taux, aucune date, aucune équivalence ni aucun fac-similé n'est inventé ;

— on ne supprime jamais une faveur pour rendre deux textes artificiellement cohérents ;

— une obligation supprimée dans une loi ne doit pas survivre dans un décret, un formulaire ou un renvoi.

4.2 Agents par article

Chaque article, ou lot d'articles liés, est traité par un agent de programmation non interactif. L'agent reçoit :

— le XML source complet, avec ses notes (NOTA), ses tableaux et ses versions ;

— les politiques applicables ;

— les cibles de renvoi explicites.

Il doit rendre l'article proposé *complet*, jamais un résumé, avec un motif et des notes de revue. Il lui attribue l'un de deux statuts, `rewrite_draft` ou `retained_unchanged`. Les abrogations et réductions partielles sont typées (`full_repeal`, `normative_reduction`). Chaque disposition retirée est listée, pour qu'une réduction soit vérifiable.

La première passe a utilisé un modèle d'OpenAI (`gpt-6-astra`, effort moyen) via l'agent en ligne de commande Codex. La seconde passe a utilisé `gpt-6.1-sol` en effort élevé.

4.3 Seconde passe : les contradictions d'abord

À partir du 23 octobre, la priorité est passée des coupes supplémentaires aux *contradictions et incohérences* : dans un article, entre articles et entre les neuf recueils. Les 30 314 propositions antérieures ont toutes été relues au regard de leurs sources et contreparties complètes. Chaque agent a classé chaque tension trouvée parmi :

— une contradiction effective ;

— une coordination nécessaire ;

— une transition compatible ;

— une différence de champ ;

— un point invérifiable.

4.4 Gardes

Rien n'est accepté sur la seule parole d'un modèle. Une réponse n'est acceptée qu'après les contrôles suivants :

— la source, les NOTA et les dates de validité ;

— la validation du contenu, y compris le balisage autorisé et les tableaux complets ;

— un contrôle d'avant-image sur cinq champs canoniques (empreinte de source, statut, proposition, motif, notes), dans la base comme dans le fichier de lot propriétaire de l'article ;

— la propriété, le registre et l'archive ;

— une validation indépendante de tout le corpus.

Les preuves d'exécution natives (modèle, effort, session) sont aussi contrôlées.

Ces gardes ne sont pas décoratives. Elles ont arrêté de vraies divergences : trois tâches de seconde passe ont été refusées parce que l'article avait changé entre-temps. Elles ont aussi rendu possible la troisième passe, puisque chaque correction a pu passer par le même écrivain.

La seconde passe s'est achevée le 29 octobre, avec l'acceptation des 30 314 identités. Un audit structurel a posteriori a ensuite relevé 94 059 points à examiner, dont 1 412 prioritaires, sur 792 articles. Ce sont des pistes, pas des contradictions établies.

5 Red team indépendante (troisième passe)

La troisième passe a utilisé un autre système : Claude Code d'Anthropic (Claude Opus 5.5 ; le dernier cycle, l'audit 8 et ses corrections, a tourné sur Claude Fable 5.1). Un agent coordinateur a lancé environ 390 sous-agents en cinq jours. Il a travaillé comme un relecteur *indépendant*, sous des règles strictes :

— lecture seule de la production, sur des instantanés figés dont tous les fichiers sont empreintés ;

— citations exactes, avec identifiant de version, pour toute affirmation ;

— aucune source, date ou « preuve de résolution » inventée ;

— aucun contournement de contrôle d'accès ;

— la mention explicite qu'une revue par IA ne vaut pas validation par un juriste.

5.1 Registre des objections

La première vague a couvert 31 dossiers thématiques (par exemple versions futures, décrets contre lois, annexes fiscales, transitions de la réforme des accidents du travail de 2026). Cinq domaines prioritaires ont suivi : l'impôt sur les sociétés à la distribution, les successions, les quotas de logements sociaux SRU, la CVAE et la taxe sur les salaires.

Chaque objection indique :

— une priorité : P0 (effet grave et certain), P1 (effet probable) ou P2 (effet limité) ;

— une nature : coordination manquante, incohérence introduite par le projet, risque juridique, conflit de source, anomalie d'inventaire, réserve documentaire ou simple alerte ;

— les passages exacts, le raisonnement et une *correction minimale* ;

— ce qu'il faut préserver : droits, faveurs et transitions.

Les 1 943 alertes structurelles jugées prioritaires par l'audit statique ont été qualifiées une à une. Les doublons ont été fusionnés avec un motif écrit (46 fusions).

5.2 Réexamen sur les différences

La seconde passe tournait encore quand la red team a commencé. Le registre a donc été réexaminé deux fois, sur un instantané intermédiaire puis sur l'instantané final, à partir d'un diff fichier par fichier. Sur le texte final, 136 objections dont l'article avait changé ont été relues :

— 58 étaient résolues par la seconde passe (dont 17 P1) ;

— 30 ont été reformulées ;

— 48 ont été maintenues.

Le registre final compte **243 objections** : 3 P0, 83 P1 et 157 P2, dont 188 confirmées et 55 à confirmer.

5.3 De la revue à la correction

Après la revue, le premier auteur a fait de la red team l'unique écrivain, avec une consigne permanente : les corrections peuvent lever des contradictions et fermer des failles, jamais changer des choix politiques. Une correction n'est appliquée que si elle fait l'une de ces trois choses :

(a) rendre effective une réforme décidée, par exemple en la reportant sur une version future publiée qui rétablirait sinon l'ancienne règle ;

(b) lever une contradiction ;

(c) fermer une faille qui contredit l'objet déclaré du projet.

Une correction est refusée si elle fait l'une des choses suivantes :

— créer ou augmenter un impôt ;

— ajouter une formalité ou une condition ;

— supprimer une exonération ou un droit acquis ;

— revenir sur un choix explicite de l'auteur ;

— trancher une question politique ouverte.

Les agents rédacteurs n'écrivent leurs corrections que dans un espace de travail, sous forme de textes d'articles complets avec des métadonnées typées. Un vérificateur reconstruit chaque ligne exactement comme le ferait l'applicateur de production, et lance le validateur du projet dans un répertoire temporaire.

Le coordinateur applique ensuite les corrections avec l'outil gardé. Cet outil contrôle l'avant-image, archive l'ancien texte, revalide tout le corpus et revient en arrière en cas d'échec. Une table de propriété attribue chaque article à un seul groupe. Les besoins entre groupes passent par des demandes, si bien que deux agents n'écrivent jamais le même article.

5.4 Contributions externes

Pendant la revue, un contributeur externe (le second auteur) a ouvert 13 issues et deux demandes de fusion sur le dépôt public. Produites avec ses propres agents d'IA, elles portaient sur des renvois du code du travail, des décrets qui survivent à des lois abrogées, des sanctions et les commissions du CSE. Chaque issue a été triée par rapport au registre, sur le texte courant. Trois d'entre elles demandaient un changement d'orientation politique ; elles ont été expliquées et closes comme non retenues.

6 Mesurer la fiabilité

Un registre dit ce qui a été trouvé, pas ce qui reste. Nous avons donc mesuré directement le taux de défauts résiduel.

Échantillonnage. Chaque audit tire environ 314 articles au hasard. Le tirage est stratifié par recueil et par niveau (législatif ou réglementaire), avec au moins six articles par strate. Chaque audit exclut tous les articles déjà lus. Les graines sont publiées.

Lecture à l'aveugle. Dix agents par audit lisent leur part « comme un juriste », sur le texte de production : l'article, ses versions futures, ses trois liens les plus importants, et ses textes d'application ou sa base légale. Ils ne consultent pas le registre avant de qualifier un article.

Verdicts. Chaque article est classé :

— **G** (grossier) : un juriste le remarquerait et le jugerait anormal ;

— **m** (mineur) : notes fausses, rédaction maladroite mais sans effet, ou doute raisonnable ;

— **0** : rien à signaler.

Tout G ou m exige une citation exacte. Les taux sont pondérés par strate, avec des intervalles à 95 %. Les défauts sont classés en dix familles :

F1	La loi supprime une formalité ou une obligation, mais un décret ou une annexe l'organise encore.
F2	Une sanction survit à l'obligation qu'elle sanctionne.
F3	Renvoi mort, décalé ou erroné.
F4	Une version future publiée, sans proposition, rétablit l'ancienne règle ; ou une abrogation affirmée à tort.
F5	Contradiction entre deux dispositions (hors F1).
F6	Transition absente ou fautive (rétroactivité, perte de droits acquis).
F7	Texte défectueux (tronqué, numérotation cassée, tableau amputé).
F8	Contraire à une orientation déclarée (impôt ou formalité recréés, faveur supprimée sans décision).
F9	Risque de droit supérieur (Constitution, droit de l'Union), toujours « à confirmer ».
F10	Notes ou motifs seulement (toujours mineur).

TABLE 2 – Familles de défauts utilisées par les auditeurs et les balayages.

Balayages par famille. Après chaque audit, nous avons transformé ses défauts grossiers en générateurs mécaniques de pistes, puis balayé tout le corpus. Exemples :

— un décret qui cite une loi abrogée ;

— une sanction qui vise un article supprimé ;

— un renvoi au n-ième alinéa d'un article qu'une proposition ou une version future a décalé ;

— une version actuelle dotée d'une proposition dont la version publiée suivante n'en a pas ;

— un décret qui emploie encore les mots distinctifs de ce que sa loi a retiré ;

— un chapitre dont seule une partie des articles est abrogée.

Une piste n'est pas un constat. Chaque piste est qualifiée par un agent qui lit les textes en entier : faux positif, déjà réglé, G ou m. Une correction est rédigée pour chaque G confirmé.

Référence. Pour savoir si un taux résiduel est bon ou mauvais, nous avons mené le même audit sur le texte *officiel* des mêmes 1 879 articles, dans les mêmes paquets, avec le même critère. Un mode « source seule » de l'outil de lecture masquait les propositions, motifs et notes du projet, et les paquets n'indiquaient pas si un article avait été réécrit. Les défauts vus d'un seul côté ont ensuite été vérifiés dans les deux textes par d'autres agents (§7.3).

Lecture systématique. Enfin, nous avons lu chaque article réécrit du CGI et de ses annexes, là où les audits montraient les taux les plus élevés. Les 2 740 articles non encore audités ont été regroupés par section, pour que chaque lecteur voie un chapitre entier. Ils ont été répartis en 132 paquets d'environ 21 articles. Chaque lecteur qualifie chaque article et rédige les corrections de ses défauts grossiers.

7 Résultats

7.1 Corrections appliquées

En six jours, la troisième passe a appliqué **1 285 lignes de correction sur 1 211 articles distincts** :

— 1 028 remplacements de propositions existantes ;

— 257 propositions nouvelles sur des versions futures publiées, qui auraient sinon rétabli le texte d'avant la réforme à leur entrée en vigueur.

Chaque ligne a été validée par le validateur du projet et archivée avec ses empreintes avant et après. Les 321 tests du projet passent après chaque tour. Le tableau 3 détaille les lignes par origine.

Origine des corrections	Pistes ou objections	Lignes appliquées
Objections P0/P1 et premières issues GitHub	86 objections	395
Objections P2	157 objections	201
Balayage 1 (renvois morts, versions futures)	1 127 pistes → 154 G	145
Balayage 2 (la loi retire, le décret garde)	1 117 pistes → 33 G	36
Défauts des audits 1 à 3, pilote « notes », issues suivantes	–	≈ 90
Tour 4 (audit 4 et balayage)	918 pistes → 45 G	64
Tour 5 (audit 5 et balayage fiscal)	548 pistes → 114 G	97
Tour 6 (audit 6 et chapitres entiers)	365 pistes → 25 G	110
Lecture systématique, CGI et annexes	2 740 articles → 96 G	81
Défauts de l'échantillon apparié encore présents	52 articles → 28 G	27
Défauts du premier échantillon frais encore présents	28 articles → 28 G	36

Table 3 – Corrections appliquées par la troisième passe, par origine. Les nombres viennent des rapports de chaque tour ; la ligne « ≈ » regroupe de petits ensembles de corrections.

7.2 Taux de défauts résiduel

Audit (état du texte)	Échantillon	G	Taux G	G ou m
1 (après corrections P0/P1)	309	12	4,0 % ± 2,2	21,1 %
2 (après balayage 1)	314	9	2,9 % ± 1,9	22,1 %
3 (après balayage 2)	314	12	3,8 % ± 2,1	17,7 %
4 (après objections P2)	314	8	2,5 % ± 1,7	14,6 %
5 (après tour 4)	314	10	3,2 % ± 1,9	22,6 %
6 (après tour 5)	314	13	4,1 % ± 2,2	15,3 %
Ensemble, audits 1 à 6	1 879	64	**3,4 % ± 0,8**	
7 (échantillon frais, texte actuel)	632	15	2,4 % ± 1,2	20,7 %
8 (second échantillon frais, texte actuel)	632	9	1,4 % ± 0,9	12,3 %

Table 4 – Huit audits aléatoires indépendants, menés à l'aveugle (verdicts bruts). Chaque échantillon exclut tous les articles déjà lus. Les audits 7 et 8 sont le côté « texte réécrit » des audits appariés frais (§7.4) ; leurs auditeurs savaient explicitement qu'un défaut hérité du texte officiel compte. L'audit 8 a tourné sur un autre modèle (Table 5.1).

Environ 3,4 % des articles (intervalle à 95 % de 2,6 à 4,2 %) portent encore un défaut grossier (tableau 4, figure 2). Autrement dit, un juriste qui lit 20 articles de sa matière a à peu près une chance sur deux de tomber sur au moins un défaut.

Le taux ne baisse pas de façon mesurable d'un tour à l'autre, alors que chaque tour corrige 50 à 110 articles. C'est attendu. Si environ 1 000 articles sont défectueux, en corriger 100 abaisse le taux d'environ 0,3 point, bien en dessous de ce qu'un audit de 314 articles peut détecter (± 2 points).

La composition des défauts, elle, a changé :

— après le premier balayage, les renvois morts (F3) ont reculé ;

— les contradictions entre deux propositions (F5) sont passées au premier plan ;

— les audits suivants se sont concentrés sur les annexes fiscales.

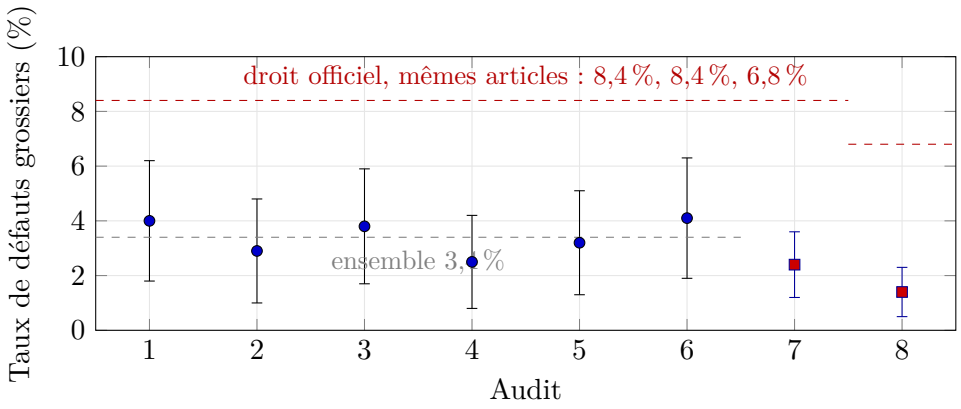


FIGURE 2 – Taux de défauts grossiers mesuré à chaque audit, avec intervalles à 95 %. Aucune baisse n'est détectable d'un tour à l'autre. La ligne rouge est le même audit mené sur le texte officiel des mêmes articles ; 8,4 % sur les deux premiers échantillons appariés et 6,8 % sur le troisième (verdicts bruts, avant vérification). Les carrés sont les audits 7 et 8, sur des échantillons frais du texte actuel.

Selon les audits, la moitié à trois quarts des défauts grossiers trouvés étaient inconnus du registre.

7.3 Référence : le droit officiel, mêmes articles

Un taux de 3,4 % est-il bon ou mauvais ? Nous avons audité le texte officiel des mêmes 1 879 articles avec la même méthode (§6).

Verdicts bruts. Les auditeurs IA ont trouvé un défaut grossier dans 158 articles officiels (8,4 % ± 1,3), contre 64 dans les audits du projet (3,4 % ± 0,8). Seuls 24 articles ont été signalés des deux côtés. La plupart des défauts officiels sont des renvois morts ou périmés (famille F3, 124 sur 158) : articles abrogés depuis des années, organismes renommés, codes recodifiés.

Vérifier les défauts contestés. La comparaison brute ne suffit pas. Sur les 966 articles que le projet a maintenus sans changement, le texte est identique des deux côtés ; pourtant, les auditeurs du texte officiel en ont signalé 30 et ceux du projet 15. Soit les deux groupes d'auditeurs n'étaient pas aussi sévères, soit les auditeurs du projet ont minoré les défauts hérités de la source.

D'autres agents ont donc vérifié chacun des 174 défauts vus d'un seul côté, dans les deux textes, en répondant à trois questions : le défaut est-il présent dans le texte officiel ? dans le texte proposé ? est-il vraiment grossier ?

Résultat. Après vérification, les articles maintenus, dont le texte est le même des deux côtés, présentent le même taux (23 et 22 défauts). La vérification semble donc effacer l'écart de sévérité. Sur cette base (tableau 5) :

— le droit réécrit compte environ **un tiers de défauts grossiers en moins** que le droit officiel qu'il remplace : 4,6 % contre 7,0 % ;

— parmi les articles réécrits, le taux passe de 11,8 % à 7,0 % ;

— pour chaque défaut introduit par la réécriture, plus de deux défauts du droit officiel ont été réparés (77 contre 32).

Mêmes articles, après vérification	Articles	Droit officiel G	Droit officiel Taux	Droit réécrit G	Droit réécrit Taux
Tous	1 879	131	7,0 % ± 1,2	86	**4,6 % ± 0,9**
Réécrits par le projet	913	108	11,8 %	64	7,0 %
Maintenus sans changement (témoin)	966	23	2,4 %	22	2,3 %
Défauts du droit officiel réparés par la réécriture					77
Défauts introduits par la réécriture					32
Test apparié (McNemar, exact)					$p \approx 2 \times 10^{-5}$

TABLE 5 – Défauts grossiers du droit officiel et du droit réécrit, sur les mêmes 1 879 articles tirés au hasard, après vérification de tout défaut vu d'un seul côté. Les chiffres du projet sont ceux de chaque audit, à sa date.

Une exception ressort. Dans la partie législative du CGI, l'échantillon compte plus de défauts vérifiés après la réécriture qu'avant (9 contre 3) : réformer l'impôt sur les sociétés et l'impôt sur le revenu crée des incohérences plus vite qu'il n'en supprime. C'est là que s'est concentrée la lecture systématique (§7).

Les chiffres du projet sont ceux de chaque audit, à sa date. Tout défaut grossier de cet échantillon encore présent dans le texte réécrit a depuis été corrigé (27 lignes, tableau 3). Cet échantillon ne peut donc plus mesurer le texte actuel sans biais : nous en avons tiré un nouveau.

7.4 Deux audits appariés frais du texte actuel

Nous avons tiré 632 nouveaux articles, jamais tirés auparavant, avec les mêmes strates et une allocation doublée. Chacun a été audité deux fois, à l'aveugle : une fois sur le texte réécrit actuel (audit 7), une fois sur le texte officiel, par 20 agents de chaque côté. Les auditeurs du texte réécrit savaient explicitement qu'un défaut hérité du texte officiel compte, ce qui rend ce côté plus sévère que dans les audits 1 à 6. Les 52 défauts vus d'un seul côté ont de nouveau été vérifiés dans les deux textes.

Les 28 défauts encore présents dans cet échantillon ont ensuite été corrigés (36 lignes), et l'audit a été répliqué sur un second échantillon frais de 632 articles (audit 8), avec le même protocole et un autre modèle (Claude Fable 5.1 au lieu de Claude Opus 5.5) ; 44 défauts vus d'un seul côté ont été vérifiés.

Échantillons frais, après vérification	Articles	Droit officiel G	Droit officiel Taux	Droit réécrit, aujourd'hui G	Droit réécrit, aujourd'hui Taux	Réparés / introduits
Audit 7 (Opus 5.5)	632	49	7,8 % ± 2,1	28	4,4 % ± 1,6	28 / 7
Audit 8 (Fable 5.1)	632	46	7,3 % ± 2,0	16	2,5 % ± 1,2	32 / 2
Ensemble	1 264	95	7,5 % ± 1,5	44	**3,5 % ± 1,0**	60 / 9
réécrits par le projet	581	84	14,5 %	35	6,0 %	
maintenus sans changement (témoin)	683	11	1,6 %	9	1,3 %	
Test apparié sur les deux échantillons (McNemar, exact)					$p \approx 2 \times 10^{-10}$	

TABLE 6 – Défauts grossiers du droit officiel et du droit réécrit actuel, sur deux échantillons frais de 632 articles chacun, jamais tirés auparavant, après vérification de tout défaut vu d'un seul côté.

Les échantillons frais confirment et précisent la comparaison appariée (tableau 6) :

— le droit réécrit actuel compte **moins de la moitié des défauts grossiers** du droit officiel : 3,5 % contre 7,5 % sur 1 264 articles ;

— parmi les articles réécrits, le taux passe de 14,5 % à 6,0 % ;

— la réécriture a réparé environ sept défauts du droit officiel pour chaque défaut introduit (60 contre 9), contre deux pour un dans le premier échantillon apparié ;

— le témoin concorde : les articles maintenus, dont le texte est identique des deux côtés, présentent 11 et 9 défauts ;

— les deux modèles concordent sur le texte officiel (7,8 et 7,3 %) ; sur le texte réécrit, Fable trouve moins de défauts (2,5 contre 4,4 %), dans les intervalles.

Les verdicts bruts donnent 8,4 et 6,8 % pour le texte officiel, contre 2,4 et 1,4 % pour le texte réécrit. Sur les 44 défauts qui restent dans le texte réécrit, 35 sont hérités du droit officiel et pas encore réparés ; 9 ont été introduits par la réécriture. Le code fiscal, exception du premier échantillon apparié, compte ici 3 défauts officiels et 5 défauts réécrits sur 96 articles.

7.5 Balayages : rendement et plateau

Le rendement des balayages a baissé à mesure que chaque famille s'épuisait. Le balayage « la loi retire, le décret garde » a donné 3 % de G par piste, contre 14 % pour le premier balayage. Seule la requalification a fait remonter le rendement : relues au seuil de l'audit, 56 des 166 pistes jugées mineures auparavant se sont révélées grossières.

Un pilote sur 250 articles dont les notes de revue annonçaient une coordination ouverte a montré que 60 % de ces notes étaient simplement périmées. Son taux de G était de 4,8 %, à peine plus que la lecture au hasard : le balayage complet n'a donc pas été lancé.

7.6 Lecture systématique du code fiscal

La lecture, chapitre par chapitre, des 2 740 articles réécrits du CGI et de ses annexes a donné :

— 96 défauts grossiers (3,5 %) ;

— 383 défauts mineurs ;

— 2 261 articles sans rien à signaler.

Ce taux de 3,5 % est bien inférieur aux 9 à 12 % que suggéraient les audits pour ces strates. Ces estimations reposaient sur de petits échantillons (76 et 128 articles), et les tours 4 à 6 s'étaient concentrés sur les annexes fiscales. Nous ne pouvons pas exclure qu'un lecteur qui parcourt un chapitre entier soit un peu moins strict qu'un auditeur à l'aveugle.

Sur les 96 défauts, 86 sont corrigés (81 lignes, dont 16 demandées entre groupes). Dix restent ouverts. Neuf sont des réformes de TVA écrites dans des subdivisions du CGI qu'une ordonnance de 2025 transfère au CIBS le 1er janvier 2027 : ces réformes seraient donc sans effet, et le CIBS est hors du corpus. Le dixième est un arbitrage politique laissé à l'auteur.

La lecture a consommé environ 30 millions de jetons (hors lectures de cache), soit environ 11 000 jetons par article.

7.7 Coût

Ce qui a été payé.

— **Passes de rédaction (Codex d'OpenAI) :** environ 1 000 dollars US de crédits API, plus un abonnement ChatGPT Pro (200 dollars par mois).

— **Troisième passe (Claude Code) :** un abonnement Claude Max (200 dollars par mois), sans crédits API facturés. Sa consommation enregistrée sur six jours est de 32 046 requêtes au modèle, 29,5 millions de jetons de sortie, 5,1 milliards de jetons lus en cache et 135 millions de jetons écrits en cache : environ **2 500 dollars** aux tarifs de l'affichage des coûts de Claude Code, ou environ 4 100 dollars aux prix publics de l'API.

En comptant un mois de chaque abonnement, la dépense réelle du projet a été d'environ **1 400 dollars**, moins de 5 centimes par article. Au prix de l'API, elle aurait été de 3 500 à 5 100 dollars, soit 12 à 17 centimes par article. Ces montants n'incluent pas le temps humain : quelques jours de direction et d'arbitrage d'une personne.

Ce que le même travail coûterait avec des juristes. C'est un ordre de grandeur, pas une mesure, et ses hypothèses sont volontairement basses. Supposons qu'un juriste mette deux heures pour réécrire un article avec un motif écrit, après lecture de ses sources et de ses contreparties ; une demi-heure pour lire un article avec ses trois liens principaux et le maintenir ou le qualifier ; une demi-heure par article pour la relecture de cohérence de la seconde passe ; une heure et demie par correction. Le travail effectivement accompli représente alors environ 36 000 heures pour la première passe (14 115 réécritures et 16 199 maintiens motivés), 15 000 heures pour la seconde (30 314 relectures) et 9 000 heures pour la troisième (environ 12 500 lectures d'audit et de balayage, 1 943 alertes qualifiées, 1 285 corrections) : à peu près **60 000 heures de juriste**, soit 35 à 40 années de travail. À un coût complet de 100 euros de l'heure pour des rédacteurs juridiques internes, cela fait environ 6 millions d'euros ; au tarif moyen d'un cabinet, 250 euros de l'heure, environ 15 millions. En divisant chaque hypothèse par deux, il reste plusieurs millions d'euros, contre environ 1 400 dollars dépensés ici. La comparaison porte sur le coût, pas sur la qualité : des juristes ne laisseraient pas 3,5 % d'articles avec un défaut grossier, et le résultat de ce projet attend encore leur relecture.

7.8 Exemples de défauts

Les exemples suivants, tous corrigés sauf mention contraire, montrent le type d'erreurs que produit la rédaction par IA et que la revue par IA peut détecter :

— *Recréer un impôt que le projet supprime.* L'inventaire avait retenu une version de l'article 1609 *quinvicies* du CGI jamais entrée en vigueur. Sa proposition rétablissait la contribution supplémentaire à l'apprentissage, que l'article L6242-1 proposé du code du travail supprime.

— *Un taux « réduit » supérieur au taux normal.* Après la réforme de l'impôt sur les sociétés, le taux réduit de 24 % des organismes sans but lucratif (CGI 219 *bis*) dépassait le nouveau taux normal de 20 %.

— *Des chapitres à moitié abrogés.* Dans l'annexe II du CGI, un tour de correction a abrogé une partie des articles sur les centres de gestion agréés, dont la base légale (CGI 1649 *quater* C à O) avait été abrogée en 2025. Les articles voisins organisaient encore la procédure d'agrément. L'audit suivant l'a relevé, et le chapitre a ensuite été traité en entier.

— *Des versions futures qui défont la réforme.* Une adaptation à Mayotte prévue pour 2028 (CSS L759-23) appliquait « dans la rédaction suivante » un article réécrit par le projet, rétablissant ainsi la règle que le projet supprime.

— *Un décret contre sa loi.* Un décret fiscal proposé supprimait l'accréditation préalable des représentants fiscaux, alors que la loi (CGI 1671) l'exigeait encore. La correction cohérente aligne la loi, au lieu de rétablir une formalité.

8 Discussion

Ce que les agents d'IA font bien. À cette échelle, les agents sont des lecteurs infatigables, complets et littéraux. Ils reproduisent des articles entiers, y compris des tableaux de plusieurs centaines de milliers de caractères. Ils suivent les renvois à travers neuf recueils et de nombreuses versions, et ils gardent des citations exactes. Avec des modifications typées et des écritures gardées, cela a permis de réécrire puis de réparer un corpus qu'aucune personne ne pourrait

relire en une semaine. Le travail est aussi entièrement vérifiable : chaque changement est archivé avec son avant-image et son motif.

Ce qu'ils font mal.

- *La frontière du corpus.* Beaucoup de défauts impliquent un texte qui n'était pas fourni : le CIBS, des lois non codifiées, des arrêtés. Un agent ne peut que les signaler comme réserves documentaires, et ne doit pas deviner.
- *Le temps.* Les textes juridiques ont des versions futures programmées. Une réforme écrite sur une version qui prend fin avant que la réforme puisse s'appliquer est sans effet. Une version future sans proposition rétablit sans bruit l'ancienne règle.
- *Une cohérence locale sans cohérence globale.* Une modification isolée est valide, mais ses voisines restent incohérentes. L'un de nos propres tours de correction a créé exactement un tel chapitre à moitié abrogé. Nous l'avons corrigé en traitant les chapitres en entier, et en lançant un contrôle de régression après chaque application : tout article qui cite encore un article abrogé au cours du tour.
- *La calibration.* Les lecteurs ne séparent pas grossier et mineur avec la même sévérité. Les premiers balayages avaient classé des renvois morts comme mineurs. Requalifiés au seuil de l'audit, un tiers d'entre eux sont devenus des défauts grossiers.

La mesure change la discussion. Sans les audits aléatoires, le nombre de corrections, plus de 1 200, aurait laissé croire à un progrès régulier. Les audits montrent un plateau autour de 3 à 4 %, et ils l'expliquent. Les balayages ciblés aident, mais les défauts restants sont dispersés. Seule une lecture systématique peut faire nettement baisser le taux. La référence appariée transforme ce plateau en résultat : le droit en vigueur n'est pas exempt de défauts non plus, et la réécriture, avec ses erreurs résiduelles, est mesurablement plus cohérente que les textes qu'elle remplace. Un taux de défauts publié, reproductible, assorti d'un intervalle et comparé à une référence nous semble le minimum pour toute affirmation sur une législation rédigée par IA.

Contradictions et politique. Tenir la red team à l'écart des choix politiques a été plus difficile que prévu. Beaucoup de contradictions apparentes ont deux résolutions cohérentes : supprimer une faveur ou l'étendre, rétablir une formalité ou en effacer le reliquat. Nous avons tranché par un critère d'alignement explicite et publié (§5), et nous avons renvoyé les vrais arbitrages à l'auteur. Un autre programme changerait le critère, pas la méthode.

La relecture par des experts. Les résultats sont produits par l'IA seule, par choix, et aucun juriste ne les a encore validés. La chaîne rend la relecture par des experts *moins coûteuse*, pas inutile : chaque article est livré avec sa source, son motif, ses notes, ses objections et sa trace d'audit. Le suivi public des issues s'est révélé le canal le plus efficace. Neuf des onze premières issues externes visaient un vrai défaut.

9 Limites

- Les résultats sont mesurés par l'IA, par choix. Les verdicts d'audit sont des jugements de modèles et peuvent se tromper dans les deux sens ; leur justesse est ouverte à la vérification par des experts, que nous invitons.
- La sévérité des auditeurs varie. Sur des textes identiques, deux groupes d'auditeurs ont différé d'un facteur deux avant vérification (§7.3). Le taux d'un audit isolé est à lire avec cette réserve. L'audit 8 a tourné sur un autre modèle que les audits 1 à 7 ; il concorde sur

le texte officiel mais trouve moins de défauts dans le texte réécrit, et un écart de sévérité entre modèles ne peut être exclu.

— Le coût « juristes » est un ordre de grandeur construit sur des hypothèses explicites, ni un devis ni une mesure.

— Le corpus est figé au 18 octobre 2026, et les textes hors des neuf recueils ne sont pas réécrits.

— Des échantillons d'audit d'environ 314 articles ne détectent que des écarts d'environ ± 2 points ; les taux par strate sont donc imprécis.

— Les modèles de rédaction et le modèle de revue viennent de fournisseurs différents, ce qui limite les angles morts communs sans les supprimer.

— Les coûts sont donnés tels que payés, avec une estimation en équivalent API pour la troisième passe. Ils n'incluent pas le temps humain et ne constituent pas une mesure de productivité.

— Les effets économiques et budgétaires de la réforme sortent du champ de cet article.

10 Conclusion et travaux futurs

Nous avons réécrit de bout en bout cinq codes français et les quatre annexes du CGI avec des agents d'IA, éprouvé le résultat par une red team indépendante, et mesuré ce qui reste faux. Mesuré contre le droit officiel sur les mêmes articles, chaque défaut contesté vérifié, le droit réécrit compte moins de défauts grossiers : 4,6 % contre 7,0 % sur 1 879 articles à la date des audits, et 3,5 % contre 7,5 % aujourd'hui, soit moins de la moitié, sur deux échantillons frais de 1 264 articles. Les quatre cinquièmes des défauts qui restent sont hérités du droit en vigueur. Le projet a coûté environ 1 400 dollars là où des juristes auraient coûté des millions. Toute la trace est publique.

Prochaines étapes :

— la lecture systématique des autres articles réécrits : construction-habitation et sécurité sociale (environ 5 500), puis travail et urbanisme (environ 5 900) ;

— l'intégration du CIBS au corpus ;

— la validation par des juristes praticiens, en commençant par les objections et arbitrages ouverts.

Au-delà de cette réforme particulière, la méthode est un modèle : une couche de politiques explicite, une rédaction complète, des écritures gardées, une red team indépendante et une mesure honnête. Nous espérons qu'elle rende le droit plus lisible, et qu'elle donne à chacun un moyen concret de vérifier la cohérence d'une réforme proposée.

Appel à contributions

Ces textes ne sont pas infaillibles : environ 3 % des articles portent encore un défaut grossier, et aucun juriste ne les a validés. Tout est public :

`https://github.com/AlexMasmej/liberer-la-france`

Nous invitons juristes, universitaires, fonctionnaires, citoyens et toute personne intéressée à aider à consolider ce code. Pour signaler un défaut, ouvrez une issue avec :

— l'article (code, numéro et identifiant `LEGIARTI`) ;

— le passage exact ;

— le problème et, si possible, une correction proposée.

Chaque issue est triée par rapport au registre. Les contradictions et les failles sont corrigées, et l'issue est close avec un lien vers le commit. Les demandes qui changeraient une orientation politique sont expliquées et closes. Les demandes de fusion sont aussi bienvenues.

Disponibilité des données et du code

Le corpus réécrit, les sources officielles, les politiques, les lots, les rapports et le registre de la troisième passe, les échantillons et verdicts d'audit, et les outils de balayage et de lecture sont publics sur `https://github.com/AlexMasmej/liberer-la-france`. Un lecteur comparatif et des téléchargements complets sont disponibles sur `https://www.libererlaretraite.com/corpus/` et `https://www.libererlaretraite.com/telechargements/`.

Usage de l'IA

Des systèmes d'IA ont effectué l'essentiel du travail de rédaction, de revue et de correction décrit ici, sous la direction et l'arbitrage d'humains. Ce manuscrit a été rédigé avec l'aide de Claude (Anthropic) à partir des archives du projet, puis relu par les auteurs.

Contributions des auteurs

Les contributions sont données selon la taxonomie CRediT.

— **Alexandre Masmejean :** Conceptualisation (a conçu le projet) ; Méthodologie (a fixé la couche de politiques) ; Investigation (a conduit les passes de rédaction) ; Supervision et Administration du projet (a dirigé le projet et arbitré tous les choix politiques) ; Rédaction – révision et édition.

— **Kevin Primicerio :** Investigation (revue externe indépendante des codes publiés avec ses propres agents d'IA) ; Validation (issues et tests d'acceptation, triés et en partie intégrés) ; Rédaction – révision et édition.

— **Nathalie Gouailhardou :** Conceptualisation (a proposé de comparer systématiquement les taux d'erreur des textes juridiques officiels et de leurs équivalents réécrits par l'IA, l'évaluation comparative des §7.3 et §7.4) ; Méthodologie (a relevé qu'évaluer différemment les textes officiels et réécrits introduirait des facteurs de confusion, et a proposé d'appliquer aux deux la même méthode et les mêmes critères d'évaluation, ce qui a établi une référence cohérente pour une comparaison valide).

Tous les auteurs ont lu et approuvé la version finale du manuscrit.

Remerciements

Nous remercions Rand Hindi, dont l'exemple a inspiré l'approche de « red teaming » de la troisième passe. Nous remercions toutes celles et ceux qui ont lu, critiqué et partagé le fil initial.

Références

[1] Conseil constitutionnel, Décision n° 99-421 DC du 16 décembre 1999, *Loi portant habilitation du Gouvernement à procéder, par ordonnances, à l'adoption de la partie législative de certains codes.*

[2] Conseil d'État, *Simplification et qualité du droit*, Étude annuelle 2016, La Documentation française, 2016.

[3] A. Masmejean (Alex Masmej, `@AlexMasmej`), Fil publié sur X, 19 octobre 2026, `https://x.com/AlexMasmej/status/2112088220804722917` (chiffres d'audience relevés le 31 octobre 2026).

[4] D. Lisnard et Nouvelle Énergie, Programme pour l'élection présidentielle de 2027, `https://www.unenouvelleenergie.fr/`.

[5] Direction de l'information légale et administrative (DILA), LEGI : codes, lois et règlements consolidés, `https://www.data.gouv.fr/datasets/legi-codes-lois-et-reglements-consolides`.

[6] N. Guha et al., LegalBench : A collaboratively built benchmark for measuring legal reasoning in large language models, *NeurIPS Datasets and Benchmarks*, 2023. arXiv :2308.11462.

[7] D. Merigoux, N. Chataing et J. Protzenko, Catala : A programming language for the law, *Proceedings of the ACM on Programming Languages* 5(ICFP), 2021. arXiv :2103.03198.

[8] Observatoire de l'innovation dans le secteur public de l'OCDE, *Cracking the Code : Rulemaking for Humans and Machines*, OCDE, 2020.

[9] D. Ganguli et al., Red teaming language models to reduce harms : Methods, scaling behaviors, and lessons learned, arXiv :2209.07858, 2022.